

第二十五屆旺宏科學獎

創意說明書

參賽編號：SA25-016

隊伍名稱：工人智慧

作品名稱：基於人工智慧之自適應輔助學習架構
探究

參賽類別：資訊

關鍵字：AST 自癒機制、強化學習、混合 RAG

摘要

本研究旨在解決現有數位學習平台依賴固定題庫、缺乏即時個人化診斷，以及生成式 AI 易產生數學推理幻覺等教學瓶頸。我們跳脫 AI 僅作為單一問答工具的框架，整合神經符號架構、強化學習與混合檢索技術，建構一套具備「診斷、出題、推薦與補救」能力的自適應輔助學習系統。

我們導入「程式即內容 (Code-as-Content)」架構，由邊緣 AI 產出可執行的 Python 程式碼，藉此動態生成邏輯相同但數值不同的無限變體題。面對邊緣模型易產生語法錯誤的缺點，以「前端鷹架提示與後端 AST 主動修復 (Active Healer)」的協同機制，透過 Regex 與 AST 分析，成功將 AI 的機率性輸出轉化為穩定且可驗證的程式碼，大幅提升出題可靠性。

在學習路徑推薦上，我們的架構結合 AKT 知識追蹤模型估計學生能力，運用 PPO 強化學習動態推薦適合的題目與策略，並且特別設計了多目標獎勵函數，將「挫折感」與「步數效率」等真實學習體驗納入考量。使得系統不僅能提升學習成效，更能兼顧路徑多樣性，給予個人化的精準引導。

而在針對學生卡關時的提問，我們以混合式 RAG (檢索增強生成) 架構。透過檢索教材與課綱內容，讓 AI 助教提供可靠的解說依據，有效減少純 LLM 可能產生的錯誤與幻覺。我們構建了一套具備高擴充性與可驗證性的智慧學習框架，展現了邊緣 AI 於國中、高中職數學教育現場作為教師輔助與學生自主學習工具的深厚潛力。

壹、前言

一、研究動機

個人化學習要能根據學生狀態，動態決定學生要「學什麼」、「如何學」以及「卡關時如何引導學生」，現有數位學習平台多依賴固定題庫、固定學習路徑或教師指派，較難即時因應不同學生在能力程度、錯誤類型與學習節奏上的差異。因此，本研究探討如何透過強化學習，根據學生知識狀態推薦合適題目。

其次，若要讓學習內容真正個人化，固定題庫本身也會形成限制。生成式 AI 雖能產生題目，但在數學教育情境中，可能出現計算錯誤或推理幻覺。邊緣 AI 具備低成本與可離線運行的優勢，但模型規模較小，更需要外部技術協助。因此，本研究進一步探討能否透過鷹架提示、程式化出題與 AST 主動修復機制，提高 AI 生成數學題目的正確性、穩定性與教學價值。

最後，學生在解題卡關時，需要符合教材脈絡與課綱內容的提示。純 LLM 若沒有讀過課綱教材或是老師指定的內容，可能產生不精確或不符合課綱的回答。因此，本研究也探討如何最佳化混合式 RAG，提升 AI 教學問答的品質與速度。

本研究以自適應學習為核心，從「題目推薦」、「題目生成」與「教學回饋」進行實驗，以人工智慧技術建構可靠、可驗證且具教育應用的輔助學習架構。

二、研究目的

- (一) 建構鷹架提示與 AST 主動修復之神經符號架構，並提出以 MCRI 指標驗證邊緣 AI 取代雲端模型於程式即內容任務中的可行性。
- (二) 比較不同強化學習設計方案對題目推薦準確度，路徑差異性等指標的影響，並找出最優動作空間及獎勵函數。
- (三) 基於混合 RAG 提升 LLM 問答品質，驗證 RAG 輔助能否達成可接受的教學效果。

貳、研究設備及器材

一、研究設備

硬體環境			軟體
型號	處理器	顯示卡	Python , Google Colab , Numpy , Matplotlib , PyTorch , Scipy , Stable-Baselines3 , Gymnasium , SymPy
桌上型電腦	Ryzen 5 7500F	RTX 5060 Ti	
ASUS TUF A14	Ryzen AI 9HX 370	RTX 4060 Laptop	
桌上型電腦	Intel Core i5	GTX 1060	
ASUS Vivobook	Intel Core i7	RTX 3050	

參、文獻回顧

一、數位學習平台(因材網)

因材網是由台灣教育部推出的數位學習平台，雖具備適性學習與生成式 AI 輔助，但仍有許多限制。其缺點如表 3-1 所示。

表 3-1：因材網缺點（表格來源：作者自行整理）

缺點	對學生造成問題
出題機制	固定題庫，學生容易背答案
教材來源	官方固定，無法根據學生客製化調整
推薦題目機制	教師指派，無法根據學生狀況調整
診斷答錯原因	教學影片，學生容易分心且無法個別化教學

本研究透過人工智慧相關技術，針對以上缺點探討可能的解法，並以人工智慧相關技術克服這些瓶頸。

二、AI 出題技術演進：從純文本到神經符號的「程式即內容 (Code-as-Content)」

雲端大型語言模型具備卓越的推理能力，但高昂成本與延遲限制了其在教育現場的應用。為實現低成本運算，邊緣 AI 成為理想替代方案，但受限於模型規模，極易產生知識衝突幻覺 (KCHs) [1]。為解決此缺點，本研究提出「雲端指導、邊緣執行」的混合架構，與 Anthropic 提出的 Agent skill 範式 [2] 高度契合，並參考 PAL (Program-aided Language Models) [3] 概念，導入「程式即內容 (Code-as-Content)」生成典範：由邊緣 AI 負責邏輯

轉譯，將計算任務卸載給 Python 直譯器，藉此根除算術錯誤並實現動態出題。

然而，在低成本的邊緣運算環境中，邊緣 AI 執行複雜出題編程時，極易產生語法崩潰與邏輯迷失。為此，我們導入神經符號 AI (Neuro-Symbolic AI) [4] 框架，結合神經網路的「創造力」與符號邏輯的「確定性」，建構出「前端鷹架防禦 + 後端符號修復」的雙層協同體系：

(一) 前端預防（鷹架理論與認知卸載）：

本研究將 Aruleba 等人 (2026) [5] 所提出的『提示工程即認知鷹架』概念具體實踐。透過預先注入標準化規格書 (MASTER_SPEC)，達成「認知卸載」，讓邊緣 AI 只需專注於邏輯轉譯，大幅降低初始生成的錯誤率。

(二) 後端治療（基於 AST 的 Active Healer 修復）：

邊緣 AI 往往缺乏 LLM 依賴自我反思 (Self-reflection) 來除錯的能力，容易引發二次錯誤 [6]。因此，本系統的 Active Healer 不使用神經網路重寫，改採 Khati 等人 (2026) 提倡的抽象語法樹 (AST) 進行確定性修復。本系統更專為「數學生成」打造修復管線：利用 AST 節點置換攔截危險函數、強制對齊安全工具庫，並輔以 Regex(正規表達式) 精準剔除 LaTeX 格式錯誤，達成超越純神經網路的修復成功率。

透過上述神經符號協同架構，本研究希望開發具有以下優勢的「程式即內容」：

1. 根除計算幻覺：符號引擎接手數值運算，確保題目絕對正確[7]。
2. 無限動態變體：產出可執行的 Python 腳本，單一程式即可衍生無限邏輯同構的變體題。
3. 極低成本：邊緣 AI 僅需一次性算力寫出程式，後續出題由本地端零成本執行。
4. 運算白箱化：運算邏輯透明，賦予系統自動生成「步驟化詳解」的能力。

三、程式碼與數學題品質的雙軌評估指標 MCRI (Math Code Reliability Index)

隨著「程式即內容 (Code-as-Content)」的興起，我們不僅需要驗證 AI 生成的程式是否強健，更需驗證其產出的內容（數學題）是否具備實際的教學價值。

(一) 程式碼生成評估的侷限與 L5 架構指標之建立

CodeBLEU 與傳統指標(如 BLEU) 相比雖引入了抽象語法樹 (AST) 與資料流分析來改善此問題[8]，但其高度依賴標準參考答案 (Golden Template)。在數學題目動態生成的

場景具備高度多樣性，導致 CodeBLEU 指標無法適用。

為解決此缺點並順應「無需標準答案的程式碼評估」[9]的學術趨勢，本研究在 MCRI 的「程式價值」軌道中，自行開發了基於 Python AST 模組的靜態程式碼分析器 (Static Code Analyzer) 作為 L5 指標。

(二) 數學題目驗證的缺口與神經符號 (Neuro-Symbolic) 典範

傳統自動評估依賴 LLM 自我檢查，然而研究證實，LLM 在多步驟數學推理時極易產生邏輯錯誤與「計算幻覺」[10]。PAL 等研究指出，將計算卸載給外部直譯器能大幅提升準確度。

因此，本研究採神經符號結合，在「題目生成階段」以自定義模組強迫模型分塊邏輯推導，保留教學透明度；在「MCRI 驗證階段 (L3)」才引入 SymPy 作為基準，確保評估公正。

(三) 教學價值的量化：從認知負荷到 MQI / IS 指標

當代研究指出，LLM 生成的數學題普遍面臨「多樣性與難度不足」的瓶頸，僅依賴 AI 往往難以產出具備高挑戰性的題目[11]。同時，數位教材的品質評估必須考量學生的認知負荷。

本研究在 MCRI 的「數學價值 (Math Value)」軌道中，設計了 MQI (數學運算廣度) 與 IS (推導步數深度) 兩個指標。IS 計算邏輯轉折的節點數，而 MQI 則量化了具備教學權重的運算子密度。透過這套指標，我們確保了 AI 生成的題目不只正確，而且具備足夠的深度。

四、自適應學習

自適應學習 (Adaptive Learning, AL)，旨在透過考量學生的個體差異 (如學術能力、偏好與學習進度)，提供客製化且動態調整的學習路徑，考慮學生的挫折等情況 [12]。

生成式人工智慧的出現，則為自適應學習帶來了改變。透過這些新技術，系統能實現實時的動態題目生成與解題回饋，不僅解決了傳統題庫固定且僵化的問題，更能在維持統計效能的同時，顯著提升學習者的成就感與適應性。

本研究便是以此理論為核心，透過強化學習與 RAG 提供推薦與檢索依據。藉由 AKT

模型對能力的估計，搭配低成本的邊緣 AI 運算，針對學生學習進度診斷與精準引導，亦能依照個人化路徑有效補強學習弱點，實現自適應學習。

五、AKT 知識追蹤模型

Ghosh 等人 (2020) [13]提出的注意力知識追蹤 (Attentive Knowledge Tracing, AKT) 以 Transformer 的自注意力機制 (Self-Attention)，用當前題目的表徵作為查詢 (Query)，從過去所有知識狀態中動態檢索最相關的資訊，使模型預測時能夠選擇性地關注最具參考價值的歷史作答，而非平等對待所有歷史記錄。本實驗即使用 AKT 模型作為強化學習環境的學生模擬器。

六、近端策略優化(PPO)

Schulman 等人 (2017) [14]提出的近端策略優化 (Proximal Policy Optimization, PPO) 是目前最廣泛使用的策略梯度強化學習演算法之一，本研究採用 PPO 作為推薦策略的訓練演算法，PPO 在保持學習穩定的同時，仍有足夠的更新幅度以維持學習效率。我們採用 Stable-Baselines3 框架[15]的 PPO 模組實作強化學習模型，每個實驗中各自的所有超參數保持一致。

七、ALPN 自適應學習路徑導航系統

Chen、Saeedvand 與 Lai (2023) [16]提出的自適應學習路徑導航系統 (Adaptive Learning Path Navigation, ALPN) 是本研究實驗二的參考文獻。ALPN 系統的核心有三點：第一，採用 AKT 作為知識追蹤模型，AKT 能更精確地分析學生的動態知識狀態，提供更可靠的推薦依據。第二，設計了以平均表現率 (Average Performance Rate, APR) 為基礎的多目標獎勵函數，APR 定義為學生對系統中所有題目的預測答對機率之均值，獎勵函數主要在鼓勵 APR 提升的同時，透過多樣性懲罰項避免系統反覆推薦相同題目。第三，提出熵增強型 PPO (Entropyenhanced PPO- EPPO)演算法。實驗在 Junyi Academy 台灣數學學習資料集上進行。本研究在此基礎上，延伸探討兩個 ALPN 未觸及的問題，其一是動作空間設計的影響，其二為加入學生情感體驗維度的多目標獎勵函數設計，形成對 ALPN 的直接延伸與拓展。

八、ZPD 理論與 Fisher Information 理論

Vygotsky (1978) 提出的近側發展區間 (ZPD)理論[17]指出，當學習任務的難度介於學生

「能獨立完成」與「完全無法完成」之間時，能激發最佳的學習成效。為將此抽象的理念落實於系統中，本研究引入了 Lord (1980)[18]的「最大費雪訊息量 (Maximum Fisher Information, MFI)」指標，讓每次推薦的題目皆落在學生的最佳學習區間內。

九、檢索增強生成 (RAG)

本研究之核心檢索系統架構，基於 Gao 等人 (2023) 在《Retrieval-Augmented Generation for Large Language Models: A Survey》中所提出的 RAG [19]。該文獻明確指出，早期的「純向量檢索 (Naive RAG)」僅依賴單一向量相似度，在面對複雜語意或領域專有名詞時，易遭遇「檢索精度低」與「語意碰撞」等瓶頸。

為突破此限制，該文獻提出了「進階檢索 (Advanced RAG)」與「模組化檢索 (Modular RAG)」的概念。本研究即是此概念的實踐：

- (一) 多路徑混合檢索的實踐：我們採用了文獻中建議的「查詢擴展 (Query Expansion)」，並結合了 Dense 密集向量與 BM25 稀疏檢索，最後以 RRF 演算法進行融合兩者結果。
- (二) 動態路由模組的整合：文中提及未來 RAG 的發展趨勢將走向「依據任務難度動態調整檢索策略」的模組化設計。我們借鑑此概念設計出「Hybrid C 動態門檻分流」架構。

十、基於大語言模型之教學評估 (LLM-as-a-Judge)

在評估生成式 AI 的教育回饋品質時，傳統的字詞重合度指標已無法衡量「邏輯推演」與「教學語氣」的好壞。為此，本研究之「實驗三：教學品質盲測」導入了 Zheng 等人 (2023) 在《Judging LLM-as-a-Judge with MT-Bench and Chatbot Arena》中所確立的自動化評估範式 [20]。

Zheng 等人的研究證實，大型語言模型在給予明確的評分準則 (Rubrics) 與少樣本提示 (Few-shot Prompting) 後，其評判結果能與人類專家的偏好達到超過 80% 的高度一致性。我們引用了此結論，設計了包含「正確性、結構、符號定義、人設穩定」四大維度的 LLM 裁判提示詞，對「純 LLM」與「RAG-LLM」的解答進行交叉盲測。

肆、研究過程與方法

一、基於提示鷹架與 AST 語法樹自癒機制之邊緣 AI 程式即內容生成優化研究

(一) Agent Skill 消融實驗流程

為了驗證鷹架提示詞及 Active Healer 的效果，我們設計了嚴謹的消融實驗。首先雲端大模型擔任架構師產出結構化的 SKILL.md 鷹架提示詞規格書。消融實驗的三個組 Ab1 (Bare) 僅使用基礎任務描述，而 Ab2 (Engineered) 與 Ab3 (Healer) 則共用同一份 SKILL.md 作為開發藍圖。程式生成完畢後，Ab3 引入「修復機制」，將其原始程式碼送入 Active Healer 進行錯誤攔截與修正。最後依據 MCRI 指標進行 100 分制的自動化評量。

(二) 實驗設計：3×3 全因子實驗

本研究採用 3×3 實驗設計，以模型規模 (Cloud/14B/8B) 與系統策略 (Ab1 Bare/Ab2 Scaffolding/Ab3 Full Healer) 為自變因，MCRI 雙軌評估體系綜合評分 (0–100 分) 為應變變因，系統性探討兩者的交互作用，整體流程如圖 4-1 所示。




圖 4-1：消融實驗流程圖（圖片來源：作者繪製）

(三) 實驗環境與樣本數

雲端大模型透過 API 進行調用、邊緣模型 (Qwen 14B/8B) 則部署於搭載 RTX 5060 Ti 之本地端消費級硬體。總計共產出 405 支 AI 生成之 Python 程式，以及 2,025 道對應之數學題目作為 MCRI 雙軌評估之樣本。

(四) 鷹架式提示工程 (Scaffolding Prompt Engineering)

為了解決邊緣 AI 從零開始寫程式容易崩潰的問題，本研究應用了認知卸載策略：預先注入工具函數庫與標準 **Import**，模型無需自行實作 **LaTeX** 轉換或分數化簡等基礎功能，僅需專注於模仿例題邏輯與參數替換核心任務，為模型搭建了多層鷹架。AI 根據鷹架提示詞產生程式之流程如圖 4-2 所示。




圖 4-2：鷹架提示生成與注入流程圖（圖片來源：作者繪製）

1. 工具庫注入：系統預先載入函數庫。模型無需重新轉寫函式，減少底層運算錯誤。
2. 規格化約束：透過表 4-1 嚴格的五步驟 **Prompt** 規範，強制模型遵循特定的演算法步驟與格式，從機率上壓制幻覺的產生。

表 4-1：鷹架提示詞五大架構規範表（表格來源：作者自行整理）

步驟	步驟名稱	目的	具體做法
1	角色定義	限縮模型輸出範疇，避免產生冗餘思考文字	嚴格定義 AI 角色為演算法工程師，禁止輸出思考過程
2	依賴注入	防止模型自行捏造不存在的函式庫	強制依賴注入，僅允許 import 標準工具庫
3	狀態結構化	避免字串拼接導致數學狀態混亂	要求使用特定資料結構（ dict ）儲存數學狀態
4	計算與渲染解耦	分離數值邏輯與排版邏輯，降低錯誤耦合	強制 Decoupling ，分開處理數值計算與 LaTeX 渲染
5	輸出格式強制	確保下游系統可直接解析，杜絕格式幻覺	最終輸出必須為嚴格的 JSON

3. 數學邊界條件約束：為確保「無限動態出題」不會產生脫離教學目標的題目，本系統在工具庫中封裝了嚴格的邊界控制函式，保證每一道題目，皆符合 **K-12** 現場的教學要求。

(五) 主動修復機制 (Active Healer)

此為本研究之核心技術。我們將修復機制模組化為四個遞進的防護層級，將 AI 的機率性輸出轉化為確定性程式碼，各層級修復目標如表 4-2 所示，修復流程如圖 4-3 所示。

表 4-2：Healer 各層級針對問題（表格來源：作者自行整理）

層級	修復器名稱	針對的問題
1	RegexHealer	中文思考過程洩漏、Markdown 殘留、while True 無窮迴圈
2	ASTHealer	縮排錯誤、函式末尾遺漏 return 語句
3	AntiDuplicationHealer	重複宣告變數、賦值順序顛倒、變數遮蔽
4	UnifiedCleanupHealer	未使用變數、深層動態執行錯誤 (RuntimeError)




圖 4-3：主動修復機制運作流程圖（圖片來源：作者繪製）

(六) MCRI 雙軌評估體系 (Math Code Reliability Index)

本研究採用了自定義的無需標準答案的程式碼評估的「MCRI 雙軌評估體系」。總分 100 分，此評估架構由以下雙軌構成。

1. 程式價值 (Program Value, 50%)：

藉由 L1 工程基石及 L2 資料衛生 (30%) 驗證語法正確性、執行效能與格式完整性、L5

架構品質 (20%) 透過 AST 進行靜態分析。

2. 數學價值 (Math Value, 50%) :

藉由 L3 數學正確 (20%)透過 SymPy 進行外在強健性驗證，確保答案正確、L4 教學有效 (30%) 透過 IS 與 MQI 指標，評估題目深度。

二、基於強化學習之自適應學習題目推薦

(一) 整體實驗架構與流程

實驗二的運作方式結合 AKT 知識追蹤模型與 RL 強化學習，首先由 AKT 模型扮演學生診斷者以及模擬學生的角色，根據學生過去的作答歷史，估計學生對每道題目的預測答對機率，形成「知識狀態向量」；接著由 PPO 強化學習模型作為課程規劃師，根據學生的知識狀態決定下一道推薦的題目。實驗流程如圖 4-4 所示。




圖 4-4：實驗二整體流程圖（圖片來源：作者繪製）

(二) 資料集選用與前處理

本實驗採用 ASSISTments 2017[21]由美國 Worcester 理工學院提供的數學作答資料集。

1. 原始資料：約 95 萬筆國高中生的數學題目作答記錄。
2. 篩選目標：選出題目數適中（7-30 道）、資料量充足（互動記錄 $\geq 3,000$ 筆）、難度合理（答對率 0.2-0.6）的知識點。
3. 篩選結果：24 個數學知識點、約 430 道題目、有效學生 1,699 位。

(三) AKT 知識追蹤模型

AKT 功能為根據學生的作答歷史（答題序列、作答結果序列），預測學生對系統中每道題目的答對機率。AKT 具有題目理解層(Exercise Encoder)、知識狀態層(Knowledge Encoder)、知識檢索層(Knowledge Retriever)三階段架構。

輸出為共 430 個數值的知識狀態向量，每個數值代表學生對某道題目的預測答對機率。

評估指標為 Val AUC，實驗 2-1（比較不同動作空間）為 0.7221，子實驗二為 0.7982 實驗詳細結果及數據見附錄二（AUC 越接近 1 表示預測越準確，0.7 以上為可接受水準）。

(四) 三種設計決策方案

實驗 2-1 比較三種不同推薦決策方法的強化學習設計。三種方案的差異是強化學習模型（PPO）每一步需要作不同的決定。圖 4-5 說明實驗 2-1 的整體運作方式，表 4-3 說明實驗 2-1 各動作空間設計方案的運作方式，表 4-4 說明實驗 2-1 中動作空間 C 中的四個策略。




圖 4-5：實驗 2-1 運作流程圖（圖片來源：作者繪製）

表 4-3：三種推薦決策方案介紹及各自優缺點（表格來源：作者自行整理）

比較項目	A：直接選題	B：先選知識點	C：選教學策略
PPO 動作空間	直接推薦題目	推薦知識點	使用哪種教學策略
選擇數量（動作空間）	430 種	24 種	4 種
題目決定方式	PPO 直接決定	ZPD 規則自動選擇	各策略規則決定
PPO 可見資訊	430 維知識狀態	24 維知識點摘要	430 + 24 + 5 維
訓練難度	最難（收斂慢）	中等	最易（收斂快）
推薦精細度	最精細	中等	由策略規則決定
可解釋性	低	中	高
訓練步數	500,000 步	200,000 步	150,000 步

而動作空間 C 採用選取教學策略的方式運行，4 種教學策略詳見表 4-4。

表 4-4：動作空間 C 各教學策略的說明（表格來源:作者自行整理）

策略	最大資訊量選題 (Fisher Information)	最弱知識(ZPD Skill)	最大知識點覆蓋 (Diversity)	最弱知識點補強 (Review)
運作方式	找出預測答對率最接近的題目	找出預測答對機率最接近 50%的知識點，並以 ZPD 方法選題	兼顧學習資訊量的同時，優先選擇學生尚未練習過的知識點	找出當前預測答對機率最低的知識點，再從中選擇答對率最高的未做過題目
特點	快速了解學生弱點及最大程度提升 APR	針對性補強特定弱點	確保學生廣泛接觸各個知識點	幫助學生重新建立信心

(五) 多目標獎勵函數比較

實驗 2-2，旨在探討在相同 RL 演算法以及相同動作空間的條件下和文獻的獎勵函數差異，ALPN 文獻的獎勵函數以平均表現率（APR）提升為核心，外加多樣性懲罰，主要衡量學習成效為主。我們在以此為基礎，增加了自適應學習導向的挫折感懲罰（ r_{frust} ）與無聊感懲罰（ r_{bored} ）以及步數效率（ r_{effic} ），實驗設計的獎勵函數包含五個部分，請見表 4-5：

表 4-5：多目標獎勵函數各項目設計說明（表格來源：作者自行整理）

獎勵項目	權重	觸發條件及細節	設計目的
r_{learn} （學習增益獎勵）	1.0	APR 提升幅度越大，獎勵越高	讓 PPO 重視學生能力的提升
r_{frust} （挫折感懲罰）	0.3	學生連續答錯，懲罰隨次數遞增（最多 5 次）	減少推薦超出學生能力範圍的題目
r_{bored} （無聊感懲罰）	0.2	答對預測答對機率超過 85%的題目	避免推薦過簡單的題目

r_diver (多樣性懲罰)	0.4	推薦已做過題目，或連續三步推薦同一知識點	確保學習路徑的廣度與多元性
r_effic (步數效率懲罰)	0.1	每步給予小額負獎勵，越接近上限懲罰越重	讓 PPO 在短步數內盡快幫助學生達標
達標額外獎勵	3.0	Skill-level APR 達到 0.65	達成學習目標為最重要之指標

(六) 評估方法

1. 學生池設定：從資料集抽取 500 位學生，其前 5 筆作答記錄作為初始狀態。其中 80% 作為訓練學生池，20%作為測試學生池，評估時使用 PPO 訓練中從未見過的學生，共在 100 個 episodes 上進行，單一 episode 的流程如圖 4-6 所示。
2. 評估指標：本實驗採用 APR(平均知識點能力)，達標率(平均知識點能力達 0.65 以上即達標)，達標步數(達標時所耗費的題數)，路徑多樣性(推薦給學生的題目順序與內容重複度)，挫折次數(在達標或推薦數達上限時學生錯題數)，知識點覆蓋(推薦的題目中涵蓋知識點量)。




圖 4-6：單一 episode 的內部流程圖（圖片來源：作者繪製）

三、基於混合 RAG 提升 LLM 問答品質

(一) 資料集選用與前處理

本實驗選用符合台灣課綱的均一教育平台（Junyi Academy）公開資料集 [22]，提取 300 個國中數學核心知識點。運用 LLM 進行文本合成，生成 300 篇對應的教材文本供系統建立向量索引。

根據 Gall (1970) 針對真實課堂提問與布魯姆認知分類（Bloom's Taxonomy）的分析研究指出 [23]，課堂中約 60% 的提問屬於低階的記憶與事實回憶，20% 為常規的程序性問題，而僅有約 20% 的提問涉及高階認知處理、邏輯分析或深層概念探究。本研究在測試題目的生成與配置上遵循此「80% 基礎常規 vs. 20% 高階複雜」的分佈規律。

(二) 實驗方法與驗證

根據 Nielsen (1993) 針對人機互動(HCI)與使用性工程的研究 [24]，系統回應時間 <1.0 秒（本研究的理論基礎）只會讓使用者感覺到稍微的延遲，但「思維的流暢性不會被打斷」。這也是為何本實驗要透過 Hybrid C 動態路由將平均延遲嚴格控制在 1 秒內的原因。實驗 3 的流程如圖 4-7 所示。




圖 4-7：實驗 3 流程圖（圖片來源：作者繪製）

1. 實驗 3-1：基礎與進階檢索演算法基準測試

目的為透過參數掃描決定後續實驗的最佳檢索深度（Top-K）。使用專針對中文語境優化

的嵌入模型 (Embedding Model)。本階段針對 Naive RAG 與 Advanced RAG 兩種核心檢索演算法進行深度 (Top-K, $K = 1$ 至 50) 參數掃描並計算命中率與平均檢索排名, 命中代表檢索正確答案出現在 k 檢索結果中, 檢索排名代表正確檢索答案在 k 筆檢索結果的平均排名。實驗 3-1 流程如圖 4-8 所示。




圖 4-8：實驗 3-1 流程圖（圖片來源：作者繪製）

2. 實驗 3-2：Hybrid RAG 動態門檻最佳化

目的是在固定由實驗 3-1 找出的最佳檢索深度 ($K = 41$) 下, 尋找動態路由系統 (Hybrid RAG) 在「運算成本 (系統延遲)」與「檢索效能 (命中率)」間的最佳平衡點。期望能使 Hybrid RAG 在 $K = 41$ 時達成「系統平均延遲低於 1 秒」, 且總命中率維持在 85% 以上的高水準。

系統依據 Naive RAG 檢索出的 Top-1 距離分數作為單題的「信心指標」, 以此決定是否放行或觸發高品質的 Advanced RAG 救援通道, 此組合稱為 Hybrid RAG。本實驗測試從 0% 至 100% 的各個百分位數作為信心門檻。在每一個門檻設定下, 計算進入快速通道 (Naive RAG) 與救援通道 (Advanced RAG) 的流量比例與延遲時間。實驗 3-2 的流程如圖 4-9 所示。




圖 4-9：實驗 3-2 流程圖（圖片來源：作者繪製）

3. 實驗 3-3：基於 LLM-as-a-Judge 的教學品質盲測評估

目的是在驗證系統（Hybrid RAG）在 1 秒極速延遲門檻下檢索出的教材，是否真能有效消除大型語言模型（LLM）的數學幻覺，並實質提升 AI 家教引導學生、導正迷思的教學品質。本實驗分為「雙軌生成」、「跨模型交叉盲測」與「人類專家一致性對比」三階段進行：

「雙軌對照組生成」：

(1) 基準組（Pure LLM）：模擬無 RAG 輔助的情境，僅給予模型「專業數學家教」之人設與學生提問，藉此擷取模型的原生知識極限與潛在幻覺。

(2) 實驗組（RAG-LLM）：模擬本系統的完整運作。將 Hybrid RAG 動態路由系統在「1 秒平均延遲」下真實檢索出的 Top-5 知識點作為外部上下文（Context）輸入，要求模型必須參考檢索內容解答。

「跨模型交叉盲測」為確保評估結果不因單一模型的偏好而失真，本研究使用 Claude Sonnet 4.6 與 Gemini 3.1 pro 兩款頂尖模型進行交叉比對。將兩組教學回覆（Answer A 與 Answer B）隨機打亂順序，消除「位置偏見（Position Bias）」。

接著邀請真實數學教師，針對同一批生成的 A/B 教學回覆提供建議。實驗 3-3 的流程如圖 4-10 所示。




圖 4-10：實驗 3-3 流程圖（圖片來源：作者繪製）

伍、至今研究結果

一、神經符號協同效應之實驗驗證

本研究透過 Ab1 至 Ab3 的消融對比，具體量化了鷹架提示與確定性修復機制兩者「缺一不可」的互補關係。首先，在未經輔助的 Ab1 階段，邊緣 AI 面臨認知超載。而 Ab2（鷹架提示詞）成功扮演了「前端預防」的角色，將重複性運算卸載給外部 Python 函數，證明了「給予正確規格與工具」遠比「一味追求參數規模」更關鍵。然而，純依賴機率生成的模型仍會殘存不可控的語法瑕疵。因此，Ab3（Active Healer）進一步作為「後端精準外科手術」，導入基於 AST 抽象語法樹的確定性防禦，將語法錯誤率降至零。

實驗結果證實，此「前端預防 + 後端治療」的神經符號協同架構，不僅彌補了邊緣小模型的先天隨機性缺陷，更將其程式生成表現，提升至優於未經修復之千億參數雲端大模型的水準。實驗詳細結果及數據見附錄一。

二、動作空間的差異性

實驗 2-1 得到以下結論與可能的原因：

- (一) 選擇知識點為動作空間的強化學習模型在知識點覆蓋度及路徑多樣性上表現不佳，推測為選擇知識點動作空間的設計缺陷，導致 PPO 學會了集中於幾個學生最弱的知識點，ZPD 在這些知識點內反覆選相近難度的題目，導致學習路徑集中。
- (二) 直接選擇題目的動作空間在各表現上皆有較佳且穩定的表現，推測為動作空間最大，模

型能達成較精細控制與推薦，適合直接使用。

(三) 選擇策略的動作空間在路徑多樣性以及覆蓋知識點的表現最佳，但是在達標率以及 APR 表現上仍有提升空間，後續可進一步優化底層的四大模組以提升 RL 的效能。

現階段的三種動作空間，以直接選題為最佳，因其在多項指標中的表現皆最高，且整體偏高。選擇知識點及策略兩種方法的底層架構需調整，選擇策略展現了和直接選題不同指標上的較佳表現，但達標率和學習成效相關指標表現普通，整體仍須修正。實驗詳細結果及數據見附錄二。

三、多目標獎勵函數的設計結果

實驗 2-2 顯示在新增更細緻多元的獎勵函數後對模型整體的表現有正向影響，在多個指標中的表現均優於 ALPN 文獻的獎勵函數，其中部分指標有明顯提升，證實加入情感維度能提升整體 RL 的表現。實驗詳細結果及數據見附錄二。

四、RAG 對於 LLM 回覆品質的提升

(一) 混合檢索能在符合使用者思考不被打斷的 HCI 1 秒標準內，達到 86.71% 的檢索教材正確率，並使檢索排序平均在前五名內。

(二) RAG 輔助 LLM 回覆具備壓倒性的品質優勢與跨模型穩健性，其中 Claude 模型具備更強的上下文整合能力

(三) LLM-as-a-Judge 在數學教育評估具備與真人教師的高度相似度。

實驗詳細結果及數據見附錄三。

五、本研究透過 3 大實驗探究，以人工智慧技術解決現有因材網缺點，如表 5-1 所示，並將研究所得結論實作整合為如圖 5-1 所示的完整架構。




圖 5-1：本研究架構整合之流程圖（圖片來源：作者自行製作）

表 5-1：自適應輔助學習系統與現有平台比較（表格來源：作者自行整理）

比較項目	因材網	自適應輔助學習平台（本作品）
出題機制	固定	Code-as-Content 程式即內容無限題庫
教材來源	官方固定	學生上傳題目或老師上傳教材自動生成程式即內容
主動推薦題目	老師指派	RL 自適應推薦題目
診斷答錯原因	純呼叫 LLM	RAG 根據教材回答與推薦迷思觀念題目練習

六、研究限制

本研究目前尚未於真實課堂進行端對端部署，針對 405 支程式與 2,025 道題目邀請資深數學教師進行專家評估，確認題目在難度鑑別、數值友善度與誘答邏輯上符合 108 課綱需求。「MCRI 量化指標＋專家質性審查」的雙重把關，為系統未來真實落地奠定基礎。

RL 訓練與評估均基於 AKT 模型模擬的虛擬學生，非真實學生即時作答。AKT 的預測誤差會累積影響 RL 的訓練品質，結論的外部效度有待真實教學場景驗證。

陸、未來研究方向

- 一、未來將持續深化神經符號 AI 複合架構，建立更穩定的自動化出題標準。
- 二、未來將嘗試把我們的系統從數學推廣至物理、化學等具備強邏輯性的理科領域。
- 三、調整強化學習模型以達到最佳效果。

- 四、將現有 RL 引入系統內實現自適應題目推薦。
- 五、在使用 Hybrid RAG 檢索時使用本地模型，並最佳化執行時間與檢索品質。
- 六、整合 Web Search 結果至 RAG，作為回答生成的輔助參考來源。
- 七、針對 RAG 的 Embedding 模型進行微調，並設計困難負樣本結合對比學習，以降低 Naive RAG 在教材檢索中的誤判。

柒、參考資料

- [1] Khati, D., & Rodriguez-Cardenas, D. (2026). Detecting and Correcting Hallucinations in LLM-Generated Code via Deterministic AST Analysis. arXiv preprint arXiv:2601.19106.
- [2] Anthropic. (2024, December 20). Building effective agents. Anthropic Engineering. <https://www.anthropic.com/engineering/building-effective-agents>
- [3] Gao, L., Madaan, A., Zhou, S., Alon, U., Liu, P., Yang, Y., Callan, J., & Neubig, G. (2023). PAL: Program-aided language models. Proceedings of the 40th International Conference on Machine Learning (ICML).
- [4] Garcez, A. d., & Lamb, L. C. (2020). Neurosymbolic AI: The 3rd Wave. arXiv preprint arXiv:2012.05876.
- [5] Aruleba, K., Esenogho, E., & Modisane, C. (2026). Prompt engineering as cognitive scaffolding for ethical and explanatory quality in AI-mediated financial learning. Discover Education, 5(1), 125.
- [6] Huang, J., Chen, X., Mishra, S., Zheng, H. S., Yu, A. W., Song, X., & Zhou, D. (2024). Large language models cannot self-correct reasoning yet. In International Conference on Learning Representations (ICLR).
- [7] Nezhad, S. B., Li, Y., & Agrawal, A. (2026). SymCode: A neurosymbolic approach to mathematical reasoning via verifiable code generation. arXiv preprint arXiv:2510.25975.
- [8] Ren, S., Guo, D., Lu, S., Zhou, L., Liu, S., Tang, D., ... & Ma, S. (2020). CodeBLEU: a method for automatic evaluation of code synthesis. arXiv preprint arXiv:2009.10297.
- [9] Tong, W., & Zhang, T. (2024). CodeJudge: Evaluating Code Generation with Large Language Models. In Proceedings of the 2024 Conference on Empirical Methods in Natural Language Processing (EMNLP).
- [10] Frieder, S., Pinchetti, L., Chevalier, A., Griffiths, R. R., Salvatori, T., Lukasiewicz, T., ... & Berners, J. (2023). Mathematical capabilities of ChatGPT. arXiv preprint arXiv:2301.13867.
- [11] Vedant Shah, et al. (2024). AI-Assisted Generation of Difficult Math Questions. arXiv preprint arXiv:2407.21009.
- [12] Baker, R. S., & Gowda, S. M. (2010). An analysis of the differences in the frequency of students'

- disengagement in urban, rural, and suburban high schools. *Proceedings of the 3rd International Conference on Educational Data Mining*, 11–20.
- [13] Ghosh, A., Heffernan, N., & Lan, A. S. (2020). Context-aware attentive knowledge tracing. *Proceedings of the 26th ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, 2330–2339.
- [14] Schulman, J., Wolski, F., Dhariwal, P., Radford, A., & Klimov, O. (2017). Proximal policy optimization algorithms. *arXiv preprint arXiv:1707.06347*.
- [15] Raffin, A., Hill, A., Gleave, A., Kanervisto, A., Ernestus, M., & Dormann, N. (2021). Stable-baselines3: Reliable reinforcement learning implementations. *Journal of Machine Learning Research*, 22(268), 1–8.
- [16] Jyun-Yi Chen, saeedy Saeedvand, and I-Wei Lai. 1; Adaptive Learning Path Navigation Based on Knowledge Tracing and Reinforcement Learning
- [17] Vygotsky, L. S. (1978). *Mind in society: The development of higher psychological processes*. Harvard University Press.
- [18] Lord, F. M. (1980). *Applications of item response theory to practical testing problems*. Lawrence Erlbaum Associates.
- [19] RAG 綜述文獻 Gao, Y., Xiong, Y., Gao, X., Jia, K., Pan, J., Bi, Y., Dai, Y., Sun, J., Wang, M., & Wang, H. (2023). Retrieval-augmented generation for large language models: A survey. *arXiv preprint arXiv:2312.10997*.
- [20] LLM-as-a-Judge 評估文獻 Zheng, L., Chiang, W. L., Sheng, Y., Zhuang, S., Wu, Z., Zhuang, Y., Lin, Z., Li, Z., Li, D., Xing, E. P., Zhang, H., Gonzalez, J. E., & Stoica, I. (2023). Judging LLM-as-a-judge with MT-Bench and Chatbot Arena. *Advances in Neural Information Processing Systems*, 36, 46595-46623.
- [21] San Pedro, M. O. Z., Ocumpaugh, J., Baker, R. S., & Heffernan, N. T. (2020). ASSISTments longitudinal data mining competition special issue: A preface. *Journal of Educational Data Mining*, 12(2), i-x.
- [22] Junyi Academy (2023). Junyi Academy Dataset. Retrieved from <https://www.junyiacademy.org/> (均一教育平台公開資料集)
- [23] Gall, M. D. (1970). The use of questions in teaching. *Review of Educational Research*, 40(5), 707-721. <https://doi.org/10.3102/00346543040005707>
- [24] HCI 回應時間經典文獻：
Nielsen, J. (1993). *Usability engineering*. Morgan Kaufmann. (pp. 134-135).


捌、附錄

附錄一、基於提示鷹架與 AST 語法樹自癒機制之邊緣 AI 程式生成優化研究之結果(實驗一)

本研究針對國中數學具備高運算複雜度的分數四則運算、整數四則運算、根號四則運算等三個單元進行規模化的消融實驗 (Ablation Study)。

(一) 消融實驗整體表現分析：邊緣 AI 反超

如附圖 1 所示，Ab1（基礎指令模式）下，雲端大模型（Gemini Flash）顯著領先，而邊緣 AI 產生嚴重幻覺與語法結構崩潰，分數落後。進入 Ab2 階段並導入結構化鷹架提示後，邊緣 AI 表現產生極大的躍升。在 Ab3 階段進一步介入基於 AST 的 Active Healer 主動修復機制後，不僅將邊緣 AI 的程式強健性推至滿分，更讓 Qwen 14B 與 8B 最終以逼近 99 分超越雲端大模型。



附圖 1：整數、分數、根號四則運算消融實驗總體效能得分結果比較圖（圖片來源：作者繪製）

(二) 實驗數據統計與顯著性檢定分析

如附表 1 所示，導入 Active Healer 的完整架構（Ab3）不僅取得最高平均分（97.41），標準差更從 Ab1 的 34.03 收斂至 1.67，證明修復機制有效剔除了 AI 隨機的極端錯誤，達成高穩定度。

其次，Kruskal-Wallis 總體檢定確認三組系統策略間存在極顯著差異（ $p < .001$ ）。最後，Ab3 與 Ab2 的事後比較展現出極大的效果量（ $d = 1.66$ ），證實邊緣 AI 的品質躍升並非隨


機巧合，而是四層修復管線介入所帶來的實質技術突破。

附表 1：各系統策略之 MCRI 評分描述性統計與差異檢定（表格來源：作者整理）


組別	平均數	標準差	Kruskal-Wallis 總體檢定	事後檢定與效果量
Ab1	41	34.03	H = 343.40、 p < .001	
Ab2	94.39	1.96		Ab2 > Ab1 (p < .001)
Ab3	97.41	1.67		Ab3 > Ab2 (p < .001, d = 1.66)

(三) 運算資源消耗與推理效能分析

如附圖 2 與附圖 3 所示，在基礎指令模式下（Ab1 階段），8B 模型單次的 Token 消耗高達約 8000 個，更導致單題生成時間長達 125 秒。本研究導入鷹架提示詞後，成功將 Token 數降至 1000 個（降幅達 87%），實現認知卸載。使本地端 Qwen 8B 模型的生成時間大幅縮短至約 25 秒（效率提升 80%）。



附圖 2：雲端模型與邊緣 AI 在分數四則運算的 token 數（圖片來源：作者繪製）



附圖 3：雲端模型與邊緣 AI 模型在分數四則運算的生成時間（圖片來源：作者繪製）

附錄二、基於強化學習之自適應學習題目推薦之結果 (實驗二)

(一) 三種動作空間設計方案比較

附表 2：動作空間的比較（表格來源:作者自行整理）（↑代表越高越好，↓代表越低越好）

策略	APR↑	達標率↑	Avg Steps	挫折次數↓	覆蓋知識點↑	DIV↑
Random（基線）	0.578	52.0%	36.74 步	20.43 次	16.00 個	0.914
PPO（直接選題）	0.594	58.0%	35.00 步	17.66 次	15.66 個	0.715
PPO（選知識點）	0.590	57.0%	38.44 步	20.21 次	8.23 個	0.472
PPO（選策略）	0.581	53.0%	38.74 步	19.30 次	16.62 個	0.783

1. Skill-APR（學習成效主指標）

三種動作空間皆優於隨機選題，直接選題最高，選擇技能次之但差距較小，選擇策略稍遜。結果顯示直接選題方案在學習成效上具有一致性的優勢，而選教學策略方案則在成效上略微落後於另外兩種設計。

2. 達標率（Success Rate）

直接選題以 58% 最高，選擇技能 57%，選擇策略 53%，前二者差距偏小，選擇策略稍遜但仍優於 Random。

3. Avg Steps（平均步數）

直接選題平均步數最短，效率最高。選知識點與選教學策略均超過 38 步，反映這兩種策略未有效引導學生快速提升 APR。直接選題和後二者差距約 3.5 步（10%）。步數短代表達成相近學習成效所需的推薦次數更少。相同成效下減少 10% 的學習時間是顯著的效益提升。

4. 挫折次數（Frustrations）

直接選題挫折次數最低（17.66 次），比 Random 少了 2.77 次（降低 13.6%），顯示 PPO 學習到了避免連續推薦過難題目的策略。PPO（選知識點）挫折次數略低於 Random，接近基線水準，推測是因為 ZPD 選題偶爾推薦難度不合適的題目，而 PPO 未能有效控制。選教學策略雖有補救策略可降低挫折，但整體挫折次數仍偏高，可能為底層規則導致。

5. 覆蓋知識點數（Skills Covered）

選知識點覆蓋知識點數僅 8.23 個，遠低於其他策略的 15–16 個，差距達一倍，推測為選擇知識點的模型只學到強化特定知識點的策略。對比之下，選教學策略覆蓋知識點數最高

(16.62)個，Diversity 策略（策略 2）的設計發揮了預期效果，有效避免知識點的重複集中。

6. DIV（路徑多樣性）

Random 的 DIV 0.914 遠高於所有 PPO，這個結果正確，因隨機選題必然每位學生的路徑都不一樣。選擇知識點僅 0.472 最低，與覆蓋知識點數偏低完全一致，所有學生都被推薦了幾乎一樣的路徑。選擇策略在 PPO 中 DIV 最高（0.783），直接選題次之（0.715）。

DIV 需要搭配成效指標分析：在檢查完原始的題目推薦路徑後，Random 的高 DIV 是低成效下的隨機多樣性，對學生幫助有限；PPO (Meta) 在維持合理成效的同時達到較高的 DIV，並兼顧路徑合理性(不會出現隨意跳題等情況)達成有意義的個人化。

(二) 多目標獎勵函數的設計效果分析

附表 3：不同獎勵函數的比較結果（表格來源:作者自行整理）

策略	APR↑	達標率↑	答對率↑	達標步數↓	挫折次數↓	DIV↑
Random（基線）	0.5641	54.0%	0.505	15.3 步	20.37 次	0.918
Greedy-ZPD（基線）	0.5895	59.0%	0.541	20.8 步	18.56 次	0.792
PPO（多目標獎勵）	0.6286	79.0%	0.574	16.9 步	12.82 次	0.747
PPO（論文獎勵）	0.6100	66.0%	0.591	19.9 步	16.49 次	0.703

（註:實驗 2-1 與 2-2 中，AKT 模型使用不同批訓練資料，兩組實驗不具直接可比性，應分別進行組內比較。）

多目標獎勵函數在 5 個指標上優於論文獎勵函數：Skill-APR、達標率、達標步數、挫折次數及 DIV 均較佳，顯示加入情感體驗維度後，在不犧牲學習成效的前提下改善了所有指標。


答對率為唯一論文獎勵略高的指標（0.591 對 0.574）：此現象源於論文獎勵的達標率較低（66%），較多學生無法達標，經檢查原始推薦路徑後發現為學生做的簡單題目較多導致。

隨機推薦的低達標步數（15.3 步）為選擇偏差所致。雖達標步數低，但隨機推薦只有 54%的達標率，而 PPO 有 79%達標，顯示 PPO 在穩定性以及教學方面，整體表現優於隨機選題。


附錄三、基於 RAG 改善學生提問回覆研究之結果 (實驗三)

(一) 實驗 3-1：基礎與進階檢索演算法基準測試

從附圖 4 與附圖 5 的實驗結果可知，在 Advanced RAG 的檢索排序平均在前五名內的情況下，k=41 為命中率最高之檢索深度。Advanced RAG 命中率: 93.02%，並且在所有 k 值命中率皆大於 Naive RAG 命中率，顯示 Advanced RAG 有較高的檢索品質。k=41 將作為後續實驗設定。



附圖 4：K 值對命中率之影響




附圖 5：K 值對平均排名之影響

(圖片來源：作者繪製)


(二) 實驗 3-2：Hybrid RAG 動態門檻最佳化

從附圖 6、7 的實驗結果可知，在回應時間小於 1 秒之目標情況下，能達到整體命中率: 86.71%，平均延遲: 0.88 秒。94.0% 的問題由高速的 Naive RAG 檢索。



附圖 6：
Hybrid RAG
命中率與延遲
之權衡 (圖片
來源：作者繪
製)


從附圖 7 的實驗結果可知，6.3% 的困難迷思提問觸發救援通道 (Advanced RAG)，81.4% 根據動態分流使用 Naive RAG。而 Naive RAG 的 12.6% 誤判推測是因為測試資料中有非常相似的單元與相近的文本，導致誤判。



附圖 7：Hybrid RAG 命中率分布（圖片來源：作者繪製）


(三) 實驗 3-3：基於 LLM-as-a-Judge 的教學品質盲測評估

由附圖 8 的實驗結果可知，RAG 有一致性的優勢，且 Claude 模型更善於整合 RAG 教材。在 Claude 的回答表現都比 Gemini 高的情況下，可以推論模型不會過度偏好自己產出的內容。



附圖 8：基於 Hybrid C 1 秒動態門檻檢索結果之跨模型交叉盲測勝率對比（圖片來源：作者繪製）

如附圖 9 所展示的實驗結果可知，人類數學老師更偏好 RAG 教材，並且與 LLM 裁判的判決只有一題的差異，印證了 Zheng 等人（2023）「人機評估具備高度一致性」的論點。



附圖 9：人類專家與 Claude 裁判之判決占比（圖片來源：作者繪製）