

第二十五屆旺宏科學獎 成果報告書

參賽編號：SA25-016

作品名稱：基於人工智慧之自適應輔助學習架構
探究

姓名：葉陽甫、林昕佑、蔡昕諾

關鍵字：AST 自癒機制、強化學習、混合 RAG

摘要

本研究建構一套自適應輔助學習架構，涵蓋動態出題、題目推薦與即時問答三部分，並以三項實驗驗證。實驗一探討提示詞工程與 AST Healer 對數學出題程式生成的影響。核心研究中，Healer 從 342 個原始 FAIL 中救回 9 個 (2.63%)，僅修復程式結構、介面、資料流與輸出格式，不修改主要演算法或數學答案；延伸驗證補齊領域 API 後，完整流程提示下的 Qwen 3.5 4B 經 Healer 修復後達 86.3% (含規則開發結果)。實驗二以 AKT 為學生模擬器、PPO 為推薦策略，比較多目標獎勵與原論文設計：兩者最終 APR 分別為 0.6710 與 0.6728，達標率均逾 98%，多目標在弱項與近期錯題推薦比例上略優，初步專家評估顯示多目標組雖有較多獲選案例，但兩名教師評估一致性較低，仍須進一步驗證路徑合理性。實驗三使用 Hybrid RAG 動態分流，94% 的提問於 0.1 秒內完成檢索，候選池命中率 86.71%、實際輸入模型之 Top-5 命中率 54.15%；於 LLM 合成資料條件下，跨模型盲測與 60 筆教師評估均顯示 RAG 組勝率較高，且此優勢自雲端模型延伸至 4B 邊緣模型。

壹、前言

一、研究動機

個人化學習需同時解決三個相輔相成的問題：其一，固定題庫難以滿足個人化學習，因此本研究探討如何透過提示鷹架與 AST Healer，提升語言模型動態生成數學題目程式的可靠性；其二，同樣的題目練習順序並不能適用於所有學生，題目推薦系統須能即時診斷學生知識狀態，動態規劃最適學習路徑，呈現最適合學生當前狀況的內容；其三，學生卡關時需要符合課綱的解說，純 LLM 在沒有讀過課綱內容下可能會產生不精確的回答，導入 RAG 檢索可提高回答品質與課綱一致性。我們希望透過人工智慧為基礎來創造一個自適應輔助系統架構，可以推薦決定練什麼、透過出題決定用什麼練習、透過 RAG 在學習卡關時給予引導。

二、研究目的

- (一) 比較不同提示資訊與語言模型所生成的數學出題程式，並探討自動修復系統在不參考正確答案的情況下，能安全修復哪些錯誤及其能力界限。
- (二) 比較不同強化學習設計方案對題目推薦內容、路徑合理性等指標的影響，並探討獎勵函數權重對路徑合理性的影響。

(三) 基於混合 RAG 提升 LLM 問答品質，比較有無 RAG 輔助之教學回覆品質差異。

貳、研究設備及器材

一、研究設備

硬體環境			軟體
型號	處理器	顯示卡	Python , Google Colab , NumPy , Matplotlib , PyTorch , SciPy , Stable-Baselines3 , Gymnasium , SymPy
桌上型電腦	Ryzen 5 7500F	RTX 5060 Ti	
ASUS TUF A14	Ryzen AI 9HX 370	RTX 4060 Laptop	
桌上型電腦	Intel Core i5	GTX 1060	
ASUS Vivobook	Intel Core i7	RTX 3050	

參、文獻回顧

一、數位學習平台（因材網）

現有數位學習平台（因材網）雖已提供題庫、學習診斷與生成式 AI 輔助，但在動態產生練習內容、依學生狀態調整後續題目以及根據教材提供即時說明等功能上，仍有進一步加強與整合的空間。因此，本研究分別從動態出題、學習路徑推薦及即時問答三個面向進行探究。現有平台功能與本研究設計之對照詳見附錄二；該對照僅用於說明功能定位，並非相同條件下的實測成效比較。

二、可執行程式與功能正確性

大型語言模型能理解數學題意並產生解題步驟，但其回答是依據文字規律生成，仍可能出現推理、公式或計算錯誤。Frieder 等人針對 ChatGPT 與 GPT-4 數學能力的研究指出，其所測試的模型雖能處理部分數學問題，但面對較複雜的內容時，答案正確性仍有限[1]。因此，讓語言模型僅以自然語言產生解答，尚不足以確保數學內容正確。

Gao 等人提出程式輔助語言模型（Program-Aided Language Models, PAL），讓語言模型將題意與解題步驟轉換為程式執行計算[2]。Nezhad 等人提出的 SymCode，則結合語言模型、程式與符號運算工具，並透過公開數學基準檢驗程式的正確性[3]。這類結合語言模型與程式的方法，可使數學推理過程實際執行、重複使用及接受檢查。

本研究進一步將上述「以程式承載數學邏輯」的概念應用於動態出題：語言模型不是直接回答單一數學題，而是產生可反覆生成同構變體題及其答案的 Python 程式。然而，程式能

夠執行，只代表語法及執行條件成立，不表示所生成的題目、答案與生成邏輯正確；模型若誤解題型結構、使用錯誤公式或不當呼叫函式，程式仍可能持續產生錯誤內容。

Liu 等人提出 EvalPlus，以實際執行測試案例評估語言模型生成程式的功能正確性。研究發現，部分通過原有測試的程式，在增加測試案例後仍會被發現錯誤，顯示測試不足可能高估程式的正確率[4]。因此，本研究以程式能否執行及答案是否正確判定 PASS/FAIL，不以程式外觀、結構相似度或能否解析作為主要依據。

此外，考量教育現場長期使用雲端大型模型可能產生持續的 API 使用成本，且校園或離線環境需要可於本地執行的系統，本研究選用可於一般個人電腦部署的中小型語言模型 Qwen 3.5 4B 與 Qwen 3.5 9B 作為主要測試對象，並納入雲端模型 Gemini 3.5 Flash 作為比較對象，以比較各模型的程式生成表現，並分析 Healer 在不同模型下的修復效果與安全邊界。

三、提示詞工程與程式生成

提示是提供給語言模型的原始題目、限制條件與可用工具。若只提供原始題目，模型必須自行規劃題目生成、答案計算流程與程式結構；若加入題目生成與答案計算步驟、函式說明或使用範例，則能進一步引導模型產生符合規格的出題程式。

Li 等人提出結構化思維鏈提示（Structured Chain-of-Thought Prompting），要求模型在生成程式前，先依循序、分支與迴圈等程式結構組織中間步驟；其在 HumanEval、MBPP 與 MBCPP 等公開基準上的表現優於一般思維鏈提示[5]。Zhou 等人提出 DocPrompting，先檢索與任務意圖相關的程式文件，再將文件提供給模型生成程式，結果顯示，相關文件有助於模型使用不熟悉的函式庫[6]。

即使增加提示資訊，仍無法保證模型產生正確程式。模型可能未遵循指定格式、錯誤呼叫函式，或產生能夠執行但答案錯誤的程式。上述研究顯示，結構化步驟與相關函式文件有助於程式生成，但資訊增加不必然帶來更高的功能正確性，因此仍須在相同題目與判定標準下，實際比較不同提示方式的生成結果。

四、AST 修復與研究缺口

程式自動修復是利用程式分析或測試，自動修改錯誤程式。抽象語法樹（Abstract Syntax Tree, AST）以具有層級關係的樹狀結構表示經過解析的程式，使系統能辨識函式、變數及運

算式等元件，並針對特定錯誤進行分析與修改。Fan 等人研究自動修復工具能否修正語言模型產生的錯誤程式，發現模型生成程式與人類程式具有部分相似的錯誤類型，顯示既有修復方法具有應用可能；但固定的修復工具仍只能處理部分錯誤，無法涵蓋所有模型生成問題[7]。

Khati 等人進一步提出以 AST 與固定規則為基礎的程式修復方法。該方法不要求語言模型重新生成程式，而是先將程式解析為 AST，再依據函式庫資訊建立的知識庫，檢查不存在的函式、錯誤參數及識別字衝突，並依固定規則進行修正。研究結果顯示，對於可由程式結構及函式規格明確判定的錯誤，此方法能提供可重複且易於追蹤的修復結果[8]。

Khati 等人的研究主要處理函式呼叫與識別字錯誤，尚未檢驗數學題目生成程式的功能正確性，也未同時比較模型規模、提示詞工程與固定規則修復的作用。基於上述研究缺口，本研究關注 AST Healer 對可由程式結構與提示規格明確判定之局部錯誤的修復，並探討其安全介入範圍與能力界限。

五、自適應學習

自適應學習（Adaptive Learning, AL）旨在透過考量學生的個體差異（如學術能力、偏好與學習進度），提供客製化且動態調整的學習路徑，考慮學生的挫折等情況。自適應學習能有效解決學習者能力不均的問題，實現個人化的適應性學習[9]。

本研究便是以此理論為核心，透過強化學習與 RAG 提供推薦與檢索依據。藉由 AKT 模型評估能力，搭配低成本的邊緣 AI 運算，針對學生學習進度診斷與精準引導，讓學生在不需具備提示工程知識的情況下，亦能依照個人化路徑有效補強學習弱點，實現自適應學習。

六、AKT 知識追蹤模型

Ghosh 等人(2020)[10]提出的注意力知識追蹤(Attentive Knowledge Tracing, AKT)，AKT 以 Transformer 的自注意力機制（Self-Attention）為基礎，採用三階段架構，依序為題目編碼器(Exercise Encoder)、知識編碼器(Knowledge Encoder)與知識檢索器(Knowledge Retriever)。AKT 能夠從過去所有知識狀態中動態檢索最相關的資訊，使模型預測時能夠關注最具參考價值的歷史作答。本實驗即使用 AKT 模型作為強化學習環境的學生模擬器。

七、近端策略優化(PPO)

Schulman 等人 (2017) [11]提出的近端策略優化 (Proximal Policy Optimization, PPO) 是目前最廣泛使用的策略梯度強化學習演算法之一，本研究採用 PPO 作為推薦策略的訓練演算法，PPO 能夠在保持學習穩定性的同時，仍允許足夠大的更新幅度以維持學習效率。我們採用 Stable-Baselines3 框架[12]的 PPO 模組實作強化學習模型，實驗中的超參數詳見附表 3。

八、ALPN 自適應學習路徑導航系統

Chen 等人 (2023) [13]提出的自適應學習路徑導航系統 (Adaptive Learning Path Navigation, ALPN) 是本研究實驗二的參考文獻。ALPN 系統的核心有三點：第一，採用 AKT 作為知識追蹤模型，AKT 能更精確地建模學生的動態知識狀態，提供更可靠的推薦依據。第二，設計了以平均表現率 (Average Performance Rate, APR) 為基礎的獎勵函數，APR 定義為學生對系統中所有題目的預測答對機率之均值，獎勵函數在鼓勵 APR 提升的同時，透過多樣性懲罰避免系統反覆推薦相同題目。第三，提出熵增強型 PPO (Entropy-enhanced PPO, EPPO) 演算法。本研究在此基礎上，延伸探討兩個 ALPN 未觸及的問題，其一是路徑的外部合理性，其二為多目標獎勵函數設計是否能改善教學邏輯及學生體驗，形成對 ALPN 的直接延伸。

九、ZPD 理論與 Fisher Information 理論

Vygotsky (1978) 提出的近側發展區間 (ZPD)理論[14]指出，當學習任務的難度略高於學生能力時，能激發最佳的學習成效。為將此理念落實於系統中，本研究引入了 Lord (1980)[15]的「最大費雪訊息量 (Maximum Fisher Information, MFI)」指標，並參考以上理論於 AKT 環境中利用模型之預測答對率 p 計算($p(1 - p)$)並實作以作為重要的比較基準模型。

十、檢索增強生成 (RAG)

本研究之核心檢索系統架構，基於 Gao 等人 (2023) 在《Retrieval-Augmented Generation for Large Language Models: A Survey》中所提出的 RAG [16]。該文獻明確指出，早期的「純向量檢索 (Naive RAG)」僅依賴單一向量相似度，在面對複雜語意或領域專有名詞時，易遭遇「檢索精度低」與「語意碰撞」等瓶頸。

為突破此限制，該文獻提出了「進階檢索 (Advanced RAG)」與「模組化檢索 (Modular

RAG)」的概念。本研究即是此概念的實踐：

多路徑混合檢索的實踐：我們採用了文獻中建議的「查詢擴展 (Query Expansion)」，並結合了 Dense 密集向量與 BM25 (關鍵字)稀疏檢索，最後以 RRF(兩榜合併名次)演算法融合兩者結果。

動態路由模組的整合：文中提及未來 RAG 的發展趨勢將走向「依據任務難度動態調整檢索策略」的模組化設計。我們借鑑此概念設計出「Hybrid 動態門檻分流」架構。

十一、基於大語言模型之教學評估 (LLM-as-a-Judge)

在評估生成式 AI 的教育回饋品質時，傳統的字詞重合度指標已無法衡量「邏輯推演」與「教學語氣」。為此，本研究之「實驗三：教學品質盲測」導入了 Zheng 等人 (2023) 在《Judging LLM-as-a-Judge with MT-Bench and Chatbot Arena》中所確立的自動化評估範式 [17]。

Zheng 等人的研究證實，大型語言模型在給予明確的評分準則 (Rubrics) 與少樣本提示 (Few-shot Prompting) 後，其評判結果能與人類專家的偏好達到超過 80% 的高度一致性。然而該一致性於英文一般對話任務取得，能否遷移至繁體中文數學教學評分尚待驗證。我們參考此研究，設計了包含「正確性、結構、符號定義、人設穩定」四大維度的 LLM 裁判提示詞，對「純 LLM」與「RAG-LLM」的解答進行交叉盲測。

肆、研究過程與方法

一、基於提示詞工程與 AST 修復之數學程式生成研究

(一) 核心研究設計與資料分組

固定題庫難以持續提供同類型但不同數值的練習，因此本實驗讓語言模型生成可重複執行的出題程式，以動態產生變體題與答案。中小型模型生成的程式可能因程式結構、領域 API 使用或輸出格式錯誤而無法使用。為提高程式生成的可靠度，本實驗比較不同模型與提示鷹架的生成表現，並建置答案盲的 AST Healer，僅修復可由固定規格唯一判定的局部錯誤，不介入數學答案與主要演算法。

本研究以 16 題國中教育會考數學題建立 Math16 題組，涵蓋多項式、根式、分數及整數四個領域，每個領域各 4 題。核心研究為 3 種模型、4 種提示方式以及 5 組預先固定之隨機

種子。3 種模型包括 Qwen 3.5 4B、Qwen 3.5 9B 與 Gemini 3.5 Flash；4 種提示方式如表 4-1 所示。

表 4-1：提示條件說明（表格來源：作者自製）

代號	提示內容	代號意義與設計說明
Ab1	僅原始題目	Ab = ablation study；作為基礎對照組，不提供額外程式規格或領域工具
Ab2g	原始題目 + 一般程式規格	g = general，提供不依數學領域區分的一般程式與輸出規格
Ab2d+api	原始題目 + 領域 API 鷹架	d = domain；API = Application Programming Interface，提供領域函式規格與呼叫方式，為研究團隊預先建立、可供模型呼叫的數學運算工具函式。
Ab2d+spec	原始題目 + 題目專屬規格鷹架	d = domain；spec = specification，提供依題目設計的精簡程式骨架與生成規則

其中，Ab2d+api 與 Ab2d+spec 所使用的領域 API 均來自先前依課本題型建立的通用工具庫；Ab2d+spec 僅依題目安排程式骨架與生成規則，未針對 Math16 各題新增或修改 API。

每一個「題目×模型×提示方式×隨機種子」的組合定義為一個實驗單元，因此核心研究共形成 $16 \times 3 \times 4 \times 5 = 960$ 個實驗單元。為避免利用主要評估結果調整提示與 Healer 規則，本研究以題目為單位，將資料分為 4 題規則開發題與 12 題保留評估題，如表 4-2 所示。

表 4-2：規則開發題與保留評估題之資料分組（表格來源：作者自製）

比較項目	4 題規則開發題	12 題保留評估題
實驗單元數	240 格	720 格
用途	提示設計、錯誤分析及 Healer 規則建置	檢驗固定提示與 Healer 規則的成效
規則狀態	可依開發結果調整	提示與修復規則均已固定
統計用途	不納入主要成效統計	作為核心研究主要評估資料

同一題所產生的所有程式均歸入相同資料組，避免同一題同時用於規則開發與主要評估。程式須通過全部測試且輸出結構符合要求，才判定為 PASS，否則判定為 FAIL，不採部分得分。模型生成程式後先進行原始評估；原始 PASS 程式不進入 Healer，僅原始 FAIL 程式接受答案盲的固定規則檢查與修復，完成後再以相同測試進行修復後評估，流程如圖 4-1 所示。

主要指標包括原始通過率、原始 FAIL 救援率及修復後通過率；其中，只有原始結果為 FAIL、修復後轉為 PASS 的程式，才計為 Healer 成功救援。




圖 4-1：核心研究之程式生成、原始評估與 Healer 修復流程（圖片來源：作者自製）

(二) AST Healer 架構與修復規則

本研究建置的 AST Healer 是一套以 Python 實作的固定規則修復程式，不呼叫語言模型重新生成程式，而是依原始碼、AST 結構、提示規格及固定規則進行局部修復。為控制修復風險，Healer 採答案盲、僅處理失敗程式及允許棄權三項原則：修復時不讀取正確答案，也不依測試結果從多種修法中選擇；只有原始評估為 FAIL 的程式才會進入 Healer；若修法無法唯一判定，即不進行修改。其修復對象及規則依處理範圍分為 Tier A - D，如表 4-3 所示。

表 4-3：各層 Healer 的處理內容與介入原則（表格來源：作者自製）

層級	主要處理內容	介入原則
A	既有的保守型語法、輸出結構及資料包裝修復	僅處理可由局部結構唯一判定的錯誤
B	擴充的表面語法與結構修復，包括全形符號、唯一缺失符號、空程式區塊及唯一匯入綁定	不改變數學運算與主要控制邏輯
C1	明確的領域 API 函式名稱錯誤	提示規格中必須存在唯一正確函式
C2	領域 API 參數與呼叫形式錯誤	只能依固定函式規格判定，不能猜測參數值
D3	隔離位於程式後方且範圍唯一的殘留內容	殘留內容不得被主要函式依賴
D1	移除模型自行定義並遮蔽系統 API 的同名類別	移除後必須能重新綁定正式系統 API
D5	依凍結條件選擇領域 API 方法	排名差距不足或存在多個候選時棄權
D2	從重複的同名定義中選擇唯一候選	無法唯一選擇時棄權，不合併程式內容

Tier A 處理基礎語法與輸出結構，Tier B 處理擴充的表面語法與結構問題，Tier C 依固定 API 規格修正函式名稱與呼叫形式，Tier D 則處理殘留內容、API 遮蔽及重複定義等較深層的程式結構衝突。D 層編號沿用規則開發時的代號，並非執行順序；本研究實際採用 D3、D1、D5 及 D2 四條規則。正式實驗固定依「A→B→C1→C2→D3→D1→D5→D2」執行，各規則以前一層處理後的程式為輸入；若不符合安全介入條件，則不修改並進入下一層。全部規則完成後，再以相同測試進行修復後評估，流程如圖 4-2 所示。




圖 4-2：AST Healer 固定規則之逐層檢查與修復流程（圖片來源：作者自製）

（三）目標性延伸驗證：完整領域 API 與 Healer 修復下的系統能力上限探索

核心研究使用先前依課本題型建置、未針對 Math16 各題增修的通用領域 API。核心研究完成後，為觀察工具、流程鷹架與修復支援較完整時，數學程式生成系統所能達到的表現，本研究補齊 16 題所需的領域 API，進行目標性延伸驗證。兩項研究的設計差異如表 4-4 所示。

表 4-4：核心研究與目標性延伸驗證之設計比較（表格來源：作者自製）

比較項目	核心研究	目標性延伸驗證
研究目的	評估一般工具條件下，模型、提示鷹架與 Healer 的整體表現	探索工具、流程鷹架與修復支援較完整時的系統能力上限
領域 API	使用依課本題型建立的通用 API，不針對 Math16 逐題補充	補齊 Math16 共 16 題所需的領域 API
提示條件	Ab1、Ab2g、Ab2d+api、Ab2d+spec	API 選單提示、完整流程提示
對應關係	Ab2d+api、Ab2d+spec 作為比較基準	API 選單對應 Ab2d+api；完整流程對應 Ab2d+spec
實驗規模	16 題×3 模型×4 提示×5 種子=960 格；其中 720 格為主要評估資料	16 題×3 模型×2 提示×5 種子=480 格
Healer 規則	Tier A-D 規則	沿用 Tier A - D 規則，並加入以 21 格完整流程原始 FAIL 開發的四類新增規則

延伸驗證分為「API 選單提示」與「完整流程提示」兩組。兩組皆使用補齊後的相同領域 API；API 選單提示提供完整的 API 規格與呼叫範例，由模型自行選擇所需 API 並規劃處理流程；完整流程提示則進一步明確指定必要 API、參數來源、呼叫順序、中間資料流與答案組裝方式。以 21 格完整流程原始 FAIL 開發的四類新增規則包括輸出欄位來源、運算元角色與順序、領域 API 呼叫正規化及處理流程串接。兩組不同提示方式與核心研究的 Ab2d+api 以及 Ab2d+spec 比較如表 4-5 所示。

表 4-5：核心研究與延伸驗證之提示條件概念對照（表格來源：作者自製）

提示角色	核心研究	延伸驗證	主要差異
模型自行規劃	Ab2d+api ：提供通用領域 API，由模型自行選擇工具及規劃流程	API 選單提示 ：補齊 16 題所需 API 後，仍由模型自行選擇工具及規劃流程	延伸驗證補齊 API，以降低工具覆蓋不足的影響
明確流程鷹架	Ab2d+spec ：依題目提供較明確的程式規格與流程提示	完整流程提示 ：在完整 API 條件下，明確指定必要 API、參數來源、呼叫順序、資料流與答案組裝方式	延伸驗證提供更完整且明確的流程指引

二、基於多目標獎勵之強化學習題目推薦

（一）整體實驗架構與流程

參考文獻[13]已透過強化學習及模擬學生構建個人化教學路徑，但多著重於學習成效，較少討論推薦路徑能否符合實際教學。因此，實驗二在原有架構上加入弱項補強、近期錯題與知識關係等教學因素，探討多目標獎勵能否在維持學習成效的同時，產生更合理的學習路徑。

實驗二由 AKT 模型扮演模擬學生，依照學生作答紀錄，輸出其對所有題目的預測答對機率，形成 673 維向量。接著由 PPO 強化學習模型根據此知識狀態決定下一道推薦的題目。實驗流程如圖 4-3 所示。




圖 4-3：實驗二整體流程圖（圖片來源：作者自製）

(二) 資料集選用與前處理

本實驗採用 ASSISTments 2017[18]由美國 Worcester 理工學院提供的數學作答資料集。從中篩選出 31 個數學知識點，673 道題目、有效學生 1,707 位，作答紀錄 265,783 筆。

(三) AKT 知識追蹤模型

AKT 功能為根據學生的作答歷史（答題序列、作答結果序列），預測學生對系統中每道題目的答對機率。AKT 具有題目編碼器、知識編碼器及知識檢索器三階段架構。

輸出為共 673 個數值的知識狀態向量，每個數值代表學生對某題目的預測答對機率，APR 為同一技能所屬題目的 AKT 預測答對機率取平均，再對 31 個技能取平均，以避免題目數量較多的技能對整體指標產生過度影響。評估 AKT 模型準確度的指標為 AUC，本研究為 0.7277（AUC 越接近 1 表示預測越準確）。

(四) 實驗 2-1 獎勵函數比較

1. Paper 組

Paper 組依照參考文獻中的獎勵函數設計移至本研究的環境中實作。主要目標是鼓勵模型提高學生的 APR。若 APR 提升，模型會得到正向回饋；若 APR 下降，則得到負面的回饋。當學生達到目標 APR 時，模型會得到額外的達標回饋，而且越早達標，獲得的回饋越高，此外，Paper 組亦依重複推薦情形給予懲罰，以降低模型持續推薦相同內容的情形。

2. 多目標組

多目標組保留 Paper 組重視的學習表現與達標效率，進一步加入教學邏輯、無聊風險及挫折懲罰，使模型在提升 APR 的同時，也能考慮推薦內容是否符合學生當下的學習需求。

由於不同獎勵項目的數值範圍不同，本研究參考[19]的方法先將各獎勵項目轉換至相近的數值尺度，再進行加權組合，以降低單一項目因數值較大而主導整體獎勵的情形。多目標獎勵函數表示如表 4-6 所示，詳細教學邏輯項目及知識圖譜詳見附表 4 至附表 9。

表 4-6：多目標獎勵函數設計（表格來源：作者自製）

項目	權重	目的
模擬學習成效	65%	維持學生 APR 提升與達標效率
教學邏輯	25%	鼓勵具有先備關係、弱項補強與合理知識銜接的推薦
挫折懲罰	6%	降低學生連續遭遇過難題目的情形
無聊懲罰	4%	減少持續推薦學生已高度可能答對的簡單題目

而其中的模擬學習成效主要保留 Paper 組的核心概念，根據 APR 變化、達標情形及完成

效率給予回饋。教學邏輯則是判斷目前推薦技能與前一技能之間是否具有先備、補救、相關或同群組關係，並考量學生對該技能的預測答對率、題目難度是否適合，以及是否出現過度重複或先備知識不足的情形。無聊風險為當模型持續推薦學生預測答對機率過高的題目時給予扣分，以減少過於簡單的推薦；若該題為間隔複習或失敗後的補強內容，則不直接視為無聊。挫折懲罰則是當學生連續答錯時逐步增加扣分，避免學生長時間停留在持續失敗的狀態。

(五) 實驗 2-2 權重敏感度分析

實驗 2-2 針對獎勵函數中的教學邏輯進行權重的調整以驗證不同獎勵函數權重對推薦結果的影響，設置 W35、W40、W45 與 W50 四組並和實驗 2-1 的 W25 進行比較。挫折懲罰與無聊懲罰固定，並比較最終模擬學習成效及路徑合理性，組別與其權重如表 4-7 所示。

表 4-7：實驗 2-2 各組獎勵函數權重（表格來源：作者自製）

組別	模擬學習成效	教學邏輯	挫折懲罰	無聊懲罰
W35	55%	35%	6%	4%
W40	50%	40%	6%	4%
W45	45%	45%	6%	4%
W50	40%	50%	6%	4%

(六) 評估方法

1. 學生池設定

正式實驗建立 400 位訓練學生及 100 位固定測試學生，每位學生以前 5 筆真實作答紀錄作為初始狀態，再由 AKT 估計其初始預測狀態。測試學生使用 AKT 訓練時未參與模型參數更新的學生，以降低 AKT 對測試學生歷史資料記憶造成的影響。

2. 評估規模

本研究之達標門檻沿用參考文獻設定內其中一組門檻，Paper 與多目標兩種方法皆使用相同 100 位測試學生，並各以 3 個 PPO 種子進行評估。

因此每一種方法共取得 300 條學習路徑作為後續分析資料。每次學習最多推薦 60 題，當 APR 達到 0.65 時，即視為成功完成該次學習。

3. 整體模擬學習成效

本研究首先評估兩種方法是否有效提升學生模擬學習成果，主要觀察 AKT 評估之最終平均預測答對率(APR)、學習增益、達標率(SR)、完成學習所需題數(平均步數)、答題正確

率，藉此判斷加入教學導向獎勵後，是否影響模擬學習成效。

4. 推薦路徑品質

除了 APR 外，本研究進一步分析推薦路徑本身，包括學生較弱的知識點推薦率、學生近期答錯的知識內容推薦比例、前後推薦知識點之相關性、跨單元轉換率、學習路徑合理性等指標。此分析用以補足只以最終 APR 判斷模型成效的不足。

5. 統計與教師評估

此外，本研究將部分 Paper 與多目標生成的路徑以匿名形式提供兩名數學教師評估，使教師在不知道模型名稱的情況下判斷推薦路徑是否符合學生弱項、近期錯誤及知識銜接需求。

研究分別將兩組 RL 的推薦路徑篩選出推薦步數相近且長度適中（8 至 60 步）的 14 組路徑進行比較，此結果反映所選 14 組配對案例的教師判斷，不代表全部推薦路徑。此部分用以補充實驗結果，檢驗模型所認定的「有效學習路徑」是否也具有實際教學上的合理性，以提供實際的教學合理性評估。

三、基於混合 RAG 提升 LLM 問答品質

學生於學習過程中產生的問題需即時且符合課綱的解說；純 LLM 未讀取課綱教材，可能附和學生的錯誤前提或產生名詞幻覺。本實驗使用混合 RAG，在可接受的延遲下於回答前檢索對應教材作為依據，並以實驗三之三驗證其檢索效率與教學品質。

（一）資料集選用與前處理

本實驗選用符合台灣課綱的均一教育平台（Junyi Academy）公開資料集 [20]，提取 301 個國中數學核心知識點。運用 LLM 進行文本合成，生成 301 篇對應的教材文本供系統建立向量索引。而教材、測試提問與檢索標準答案均由語言模型合成，故命中率為模擬條件下的估計。

根據 Gall (1970) 針對真實課堂提問與布魯姆認知分類（Bloom's Taxonomy）的分析研究指出 [21]，課堂中約 60% 的提問屬於低階的記憶與事實回憶，20% 為常規的程序性問題，而僅有約 20% 的提問涉及高階認知處理、邏輯分析或深層概念探究。本研究在測試題目的生成與配置上遵循此「80% 基礎常規 vs. 20% 高階複雜」的分佈規律。

(二) 實驗方法與驗證

Nielsen (1993) 提出三段回應時間門檻：0.1 秒（感覺即時）、1 秒（思緒不被打斷）、10 秒（注意力極限）[22]。本研究以 1 秒門檻作為分流設計依據，使多數提問維持在思緒不被打斷的範圍；救援通道落在 1 至 10 秒區間，極端案例超過 10 秒，依 Nielsen 之建議應於實現系統時提供進度回饋，並可設定逾時上限（如 10 秒）。實驗三的流程如圖 4-4 所示。




圖 4-4：實驗三流程圖（圖片來源：作者自製）

1. 實驗 3-1：基礎與進階檢索演算法基準測試

目的為透過參數掃描決定後續實驗的最佳檢索深度（Top-K）。使用專門針對中文語境優化的嵌入模型（Embedding Model）。本階段針對 Naive RAG 與 Advanced RAG 兩種核心檢索演算法進行深度（Top-K， $K = 1$ 至 50）參數掃描並計算命中率與平均檢索排名，命中代表檢索正確答案出現在前 k 筆檢索結果中，檢索排名代表正確檢索答案在 k 筆檢索結果的平均排名。

2. 實驗 3-2：Hybrid RAG 動態門檻最佳化

目的是在固定由實驗 3-1 找出的最佳檢索深度（ $K = 41$ ）下，尋找動態路由系統（Hybrid RAG）在「運算成本（系統延遲）」與「檢索效能（命中率）」間的最佳平衡點。期望能使 Hybrid RAG 在多數提問上於 1 秒內完成檢索，同時將總命中率維持在 85% 以上的高水準。

系統依據 Naive RAG 檢索出的 Top-1 距離分數作為單題的「信心指標」，以此決定是否放行或觸發高品質的 Advanced RAG 救援通道，此組合稱為 Hybrid RAG。本實驗測試從

0% 至 100% 的各個百分位數作為信心門檻。在每一個門檻設定下，計算進入快速通道 (Naive RAG) 與救援通道 (Advanced RAG) 的流量比例與延遲時間。實驗 3-2 的流程如圖 4-5 所示。




圖 4-5：實驗 3-2 流程圖（圖片來源：作者自製）

3. 實驗 3-3：基於 LLM-as-a-Judge 的教學品質盲測評估

目的是在驗證系統 (Hybrid RAG) 在 1 秒極速延遲門檻下檢索出的教材，是否真能有效減少大型語言模型 (LLM) 的數學幻覺，並實質提升 AI 家教引導學生、導正迷思的教學品質。本實驗分為「雙軌生成」、「跨模型交叉盲測」與「人類專家一致性對比」三階段進行。

「雙軌對照組生成」：

- (1) 基準組 (Pure LLM)：模擬無 RAG 輔助的情境，僅給予模型「專業數學家教」之人設與學生提問，藉此擷取模型的原生知識極限與潛在幻覺。
- (2) 實驗組 (RAG-LLM)：模擬本系統的完整運作。將 Hybrid RAG 動態路由系統在「1 秒平均延遲」下真實檢索出的 Top-5 知識點作為外部上下文 (Context) 輸入，要求模型必須參考檢索內容解答。

雲端組測試筆數為 60 筆，本地模型組測試筆數為 301 筆，其中前 60 筆與雲端組相同。

「跨模型交叉盲測」為確保評估結果不因單一模型的偏好而失去公平性，本研究使用 Claude Sonnet 4.6 與 Gemini 3.1 Pro 兩款模型交叉比對。將兩組教學回覆隨機打亂順序，消除「位置偏見」。接著邀請一位真實數學教師，針對 60 筆雲端組回覆提供建議。

伍、研究結果

一、基於提示詞工程與 AST 修復之數學程式生成研究

(一) 三種模型與四種提示方式的原始生成結果

以 12 道未參與規則建置的 Math16 保留題，共 720 個實驗單元，比較三種模型在四種提示方式下、Healer 介入前的原始通過結果，如圖 5-1 所示。




圖 5-1：三種模型在四種提示方式下的原始通過率（圖片來源：作者自製）

由圖 5-1 可見，在四種提示條件下，Gemini 3.5 Flash 的原始通過率均為最高，Qwen 3.5 9B 亦均高於 Qwen 3.5 4B。兩個 Qwen 模型皆在 Ab2d+spec 條件下表現最佳，在 Ab2d+api 條件下表現最低，且低於僅提供原始題目的 Ab1（4B 由 23.3% 降至 8.3%，9B 由 30.0% 降至 21.7%）。兩項提示條件的差異，將於目標性延伸驗證中透過補齊領域 API 進一步比較。

在本研究的 240 組配對中，Qwen 3.5 9B 整體通過 85 格，高於 Qwen 3.5 4B 的 63 格。由於同一題下不同提示方式與生成種子的結果可能存在相依性，本研究將此結果作為研究設定內的描述性比較，不推論至其他題目或模型。

(二) Healer 的修復成效與能力邊界

在 720 個原始生成結果中，378 格原始 PASS 不進入 Healer，僅 342 格原始 FAIL 進入固定的 Healer 修復流程。圖 5-2 以三種模型在四種提示方式下的原始 PASS 為底，紅色區段表示原始 FAIL 經 Healer 處理後轉為 PASS 的新增救援。




圖 5-2：三種模型在四種提示方式下的原始 PASS 與 Healer 新增救援（圖片來源：作者自製）

在 342 格原始 FAIL 中，Healer 成功救回 9 格，原始 FAIL 救援率為 2.63%（9／342）。為分析 Healer 成功救援的錯誤類型，本研究合併三種模型與四種提示方式，依評估流程中最早出現的失敗位置，將 342 格原始 FAIL 互斥歸入 L0 至 L5，結果如表 5-1 所示。

表 5-1：各失敗層級的原始 FAIL 與 Healer 救援結果（表格來源：作者自製）

失敗層級	主要錯誤類型	原始 FAIL	成功救援	救援率
L0	系統或基礎設施失敗	0	0	—
L1	程式擷取、解析或語法失敗	114	1	0.88%
L2	格式、函式入口或輸出包裝失敗	22	6	27.27%
L3	領域 API 或工具使用失敗	3	0	0%
L4	執行、組裝或資料流失敗	59	2	3.39%
L5	答案或演算法錯誤	144	0	0%
合計		342	9	2.63%

註：救援率＝該層成功救援數÷該層原始 FAIL 數；L0 沒有原始 FAIL，因此不計算救援率。

9 格救援中，8 格來自 Qwen 3.5 4B，1 格來自 Qwen 3.5 9B，Gemini 3.5 Flash 沒有新增救援。342 格原始 FAIL 中共有 42 格曾被 Healer 修改，其中 9 格由 FAIL 轉為 PASS，另 33 格仍為 FAIL；在實際發生修改的 42 格中，修改後救援比例為 21.43%（9／42）。逐格稽核未觀察到程式由可解析退化為不可解析，但現有紀錄不足以判定所有錯誤面向的前後變化。整體而言，Healer 的救援集中於可由固定規格唯一判定的局部介面與資料流錯誤，未修復答案或核心演算法錯誤。

(三) 目標性延伸驗證

為區分領域 API 覆蓋不足與工具流程規劃的影響，本研究補齊 16 題所需的領域 API，比較 API 選單提示與完整流程提示。兩者使用相同工具；完整流程提示另明確指定必要 API、參數來源、呼叫順序、中間資料流及答案組裝方式，結果如圖 5-3 所示。




圖 5-3：三種模型在核心研究與延伸驗證之對應提示條件下的原始 PASS 與 Healer 新增救援（圖片來源：作者自製）

在 Ab2d+api 與 API 選單提示的對照中，Qwen 3.5 4B、Qwen 3.5 9B 及 Gemini 3.5 Flash 的原始通過率，分別增加 24.17、48.33 及 3.33 個百分點。在 Ab2d+spec 與完整流程提示的對照中，4B 與 9B 分別增加 33.33 及 42.08 個百分點，Gemini 則維持 100%。由於核心研究與延伸驗證的題目範圍及領域 API 設定不同，以上結果屬於兩階段間的描述性對照。

在延伸驗證內部，完整流程提示相較於 API 選單提示，使 Qwen 3.5 4B 的原始通過率提高 47.50 個百分點，Qwen 3.5 9B 提高 23.75 個百分點；Gemini 3.5 Flash 在兩種提示下均為 100%，未出現差異。

Healer 新增規則以完整流程提示的 21 格原始 FAIL 進行開發，其中 Qwen 3.5 4B 有 16 格、9B 有 5 格，最終救回 5 格，且均來自 4B；此部分屬規則開發結果。規則凍結後套用於 API 選單提示時，4B 的 54 格原始 FAIL 中救回 4 格，救援率為 7.41%；9B 的 24 格原始 FAIL 未新增救援，Gemini 則沒有原始 FAIL。

二、基於多目標獎勵之強化學習題目推薦

(一) 實驗 2-1 多目標獎勵函數效果分析




圖 5-4：各模型之模擬學習成效 (APR)




圖 5-5：各模型之達標率




圖 5-6：各模型之平均推薦步數




圖 5-7：各模型之平均答對率




圖 5-8：各模型之平均模擬學習增益 (圖片來源：作者自製)

如圖 5-4 至 5-8 所示，Paper 與多目標模型的最終 APR 分別為 0.6728 與 0.6710，兩者均高於 ZPD 與 Random；兩組 RL 達標率分別為 99.00% 與 98.33%。在學習效率方面，Paper 與多目標模型平均約需 8.6 步即可完成學習，少於兩組非強化學習基線。平均答對率方面，多目標模型為 62.66%，Paper 為 61.55%，答對率主要計算推薦路徑中模擬作答正確的比例。多目標模型可能推薦較符合學生當下程度、較容易答對的題目，因此路徑答對率較高；Paper 則更直接選擇能提升全體題目平均預測答對率的題目，因此最終 APR 可能略高。整體而言，兩種 PPO 策略在模擬學習成效上表現接近，並較非強化學習基線有較高的 APR、答對率及較快的達標步數。

(二) 推薦路徑評估與教師盲測

- 實驗 2-1 透過比較 RL 模型推薦路徑並分析路徑是否合理，符合教學邏輯，作為實驗的教師觀點審查及合理性評估，如表 5-2 所示，多目標在各項自動路徑合理性指標表現均較 Paper 組佳，但整體路徑合理性改善幅度仍有限。

表 5-2：學習路徑之分析結果（表格來源：作者自製）

指標	Paper	多目標	多目標-Paper
弱項相關推薦比例	50.67%	54.02%	+3.35 個百分點
第一步為弱項相關單元	49.00%	54.33%	+5.33 個百分點
最近錯題相關推薦比例	8.00%	9.19%	+1.19 個百分點
第一步為最近錯題相關單元	8.67%	10.00%	+1.33 個百分點
相關單元轉移率	23.11%	24.55%	+1.44 個百分點
不符合知識圖譜之轉移率	76.89%	75.45%	-1.44 個百分點

2. 教師盲測




圖 5-9：教師盲測結果
（圖片來源：作者自製）

如圖 5-9 所示，兩位教師盲測結果呈現較大的相異性，教師 1 判定有 10 組兩條路徑皆不適合、3 組多目標勝出、1 組平手。而教師 2 評估認為 6 條多目標勝出，4 條 Paper 組勝出，4 條平手，兩者評估方向差異較大。結果顯示，多目標雖獲選較多，但仍待後續詳細評估。

(三) 實驗 2-2 不同權重下多目標獎勵對於推薦結果之影響




圖 5-10：各權重平均答對率




圖 5-11：各權重平均推薦步數




圖 5-12：各權重平均 APR




圖 5-13：各權重達標率（圖片來源：作者自製）

表 5-3：各權重學習路徑分析結果（表格來源：作者自製）（註：W25 為實驗 2-1 之權重）

組別	弱項相關推薦率	第一步弱項相關率	近期錯題相關推薦率	第一步近期錯題相關率	相關單元轉移率	不符知識圖譜轉移率
W25	54.02%	54.33%	9.19%	10.00%	24.55%	75.45%
W35	54.79%	55.33%	9.15%	13.00%	23.59%	76.41%
W40	52.81%	53.67%	10.39%	14.33%	23.53%	76.47%
W45	51.10%	47.67%	10.74%	12.33%	25.30%	74.70%
W50	57.91%	56.00%	10.13%	14.00%	24.76%	75.24%

如圖 5-10 至 5-13 所示，提高教學邏輯權重後，各組仍能維持相近的 APR。其中，W35 具有最高的最終 APR 與達標率，且平均僅需 7.79 步；W45 的平均答對率最高，但平均路徑增加至 10.57 步。隨教學邏輯權重提高，平均步數整體增加，但 APR、達標率與答對率並未呈現一致的單調變化。

而如表 5-3 所示，路徑指標亦呈現不同組別各有優勢的情形。W50 的弱項相關推薦率最高，W45 則具有較高的近期錯題相關推薦率及圖譜可解釋轉移率。然而，各項路徑指標並未隨教學邏輯權重增加而持續改善，且部分組別的差異與種子間波動幅度相近。

整體而言，提高教學邏輯權重能使部分模型更重視學生的弱項與近期錯誤，但無法保證推薦路徑同步變得更連貫。不同權重會形成不同的推薦特性。

三、基於混合 RAG 提升 LLM 問答品質

（一）實驗 3-1：基礎與進階檢索演算法基準測試

從圖 5-14 與圖 5-15 的實驗結果可知，Advanced RAG 在正確答案平均排名在前 5 名以內的情況下，K=41 為命中率最高之檢索深度。Advanced RAG 命中率：93.02%，並且在所有 K 值命中率皆大於 Naive RAG 命中率，顯示 Advanced RAG 有較高的檢索品質。K=41 作為實驗 3-2 的檢索深度設定。




圖 5-14：K 值對平均排名之影響

(圖片來源：作者自製)




圖 5-15：K 值對命中率之影響

(二) 實驗 3-2：Hybrid RAG 動態門檻最佳化

從圖 5-16 的實驗結果可知，於選定門檻下，94.0% 的提問由快速通道處理並於 0.1 秒內完成，其中命中佔全體 81.4%。其餘 6.0% 觸發救援通道（單題 14.7 秒）。整體檢索命中率為 86.71%，延遲分佈為 P50 = 0.1 秒、P90 = 0.1 秒、P95 與 P99 為 14.7 秒，加權平均為 0.97 秒，多數互動維持在不打斷思考流暢性的範圍內。分流比例詳見附圖 1。

此外，K=41 為 RRF 融合階段的候選池深度，而實際注入模型的上下文為 Top-5 知識點。在 Top-5 深度下，Naive RAG、Advanced RAG 與 Hybrid RAG 的命中率分別為 52.82%、70.76% 與 54.15%，MRR@5 (正解在前 5 筆中的名次倒數平均)分別為 0.375、0.533 與 0.385。因此實驗 3-3 的教學品質提升，是在「約半數提問可取得正確教材、其餘提問取得相關但非標準答案之教材」的條件下達成，而非以 86.71% 的候選池命中率為前提。




圖 5-16：Hybrid RAG 命中率與延遲之權衡（圖片來源：作者自製）

為檢驗檢索深度與信心門檻是否對本批資料過度配適，本實驗將 301 題隨機切分為開發集（150 題）與測試集（151 題），僅於開發集上重新選定最佳 K 值與信心門檻，再於測試集回報命中率；重複 5 組隨機切分，測試集命中率為 $86.89\% \pm 3.01\%$ ，與全資料集之 86.71% 無實質差異。

(三) 實驗 3-3：基於 LLM-as-a-Judge 的教學品質盲測評估

由圖 5-17 可知，兩個生成模型的 RAG 版本相對於各自的 Pure LLM 版本皆取得優勢，且同一生成模型在兩位不同裁判下均呈現一致結果，顯示此優勢並非由單一裁判的偏好所造成。此外，人類教師於 60 題中全數判定 RAG 組勝出，Claude 裁判判定 RAG 勝出者為 98.3%，因人類判決無變異，校正偶然一致後的 Cohen's kappa 為 0.00，故僅能說明兩者在本批題目上的結論方向相同，詳見附圖 2。




圖 5-17：雲端模型動態門檻檢索結果之跨模型交叉盲測勝率（圖片來源：作者自製）

由圖 5-18 的實驗結果可知，邊緣模型 Qwen 3.5 4B 導入 RAG 後同樣呈現一致的品質優勢，RAG-LLM 的獲勝率約為純 LLM 的三倍，顯示此優勢並非來自單一裁判的偏好。但邊緣模型的勝率低於兩款雲端模型，顯示模型規模會影響整合外部教材的效率，詳見附圖 3。勝率受回覆長度影響程度，詳見附錄一(五)。




圖 5-18：邊緣端模型 Qwen 3.5 4B 之跨裁判交叉盲測勝率（圖片來源：作者自製）

陸、討論

一、基於提示詞工程與 AST 修復之數學程式生成研究

(一) 工具覆蓋與流程鷹架共同影響小模型表現

核心研究顯示，增加提示資訊不等於提高功能正確性。兩個 Qwen 模型在 Ab2d+api 下不僅未優於 Ab1，表現反而下降，而 Ab2d+spec 則表現最佳。這可能是因為通用 API 尚未完全覆蓋題目需求，且模型仍須自行完成工具選擇、參數判斷與資料流安排，使增加的資訊反而擴大決策空間；Ab2d+spec 則透過程式骨架與生成規則，縮小模型需要自行規劃的範圍。

延伸驗證補齊題目所需 API 後，在使用相同工具的條件下，完整流程提示仍優於 API 選單提示，顯示工具覆蓋與流程規劃皆會影響生成表現。較小模型從流程鷹架獲得的幫助較大，接近表現上限的模型則提升有限，說明提示鷹架的價值在於預先整理工具與處理流程，而不只是增加資訊。

(二) Healer 的修復成效取決於錯誤分布與安全邊界

Healer 在核心研究中的成功救援率為 2.63%，此數值必須與原始失敗程式的錯誤分布共同解讀。342 格原始 FAIL 中，有 144 格屬於 L5 答案或演算法錯誤，約占 42%。這類錯誤需要重新理解題意、選擇解法或改寫核心演算法，本來就不在 Healer 的修復範圍內。其餘 L1 至 L4 錯誤中，也只有錯誤位置明確、修法唯一且不涉及重新解題的部分適合自動修改。因此，Healer 的整體救援率反映了原始錯誤分布與保守修復邊界。其研究價值不在於修復所有失敗程式，而在於明確區分可由程式規格修復的局部問題，以及需要重新解題、無法介入的數學推理問題。

各模型的救援分布也呈現相同趨勢：救援主要集中於 Qwen 3.5 4B，9B 僅有少量救援，Gemini 則沒有新增救援。隨著模型能力提高，語法、介面及輸出包裝等局部錯誤逐漸減少，殘留錯誤較多轉向答案、演算法及數學推理等較深層問題，使符合 Healer 介入條件的情形自然減少。這表示模型越強，Healer 需要處理的問題越少，而不是 Healer 失去作用。

本研究的 Healer 不讀取正確答案、不以測試結果挑選修法，也不重新呼叫語言模型生成程式；只有在固定規格能唯一決定修法時，才進行最小幅度修改。此設計雖然限制了救援數量，卻能避免修復器越過程式修正與重新解題之間的界線。其核心定位可以概括為：「Healer 修復程式與答案格式，不修復數學答案。」因此，Healer 的研究價值不在於追求最高修改率，而在於以可重複、可追溯且允許棄權的方式，保守處理生成後殘留的局部錯誤。

(三) 延伸驗證顯示整套方法具有實務應用潛力

延伸驗證顯示，即使提供完整領域 API，模型仍可能受限於工具選擇、參數來源與流程串接；當這些步驟由完整流程提示清楚指定後，兩個 Qwen 模型的程式生成表現皆有提升，其中 4B 的改善幅度較大。在完整領域 API、完整流程提示與 Healer 共同作用下，4B 修復後通過率達 86.3%，顯示中小型模型可透過提示詞工程與後端修復的分工提高可靠度。此數值包含 Healer 規則開發結果，因此用於呈現整套配置下的表現，不作為未見題目的泛化證據。

在本研究設定下，領域 API 提供解題工具，完整流程提示降低規劃負擔，Healer 則修補生成後修法唯一的局部錯誤。三者分工可提高小型模型的程式生成可靠度，但實際部署效益仍需後續驗證。

二、基於多目標獎勵之強化學習題目推薦

(一) 實驗 2-1 基線模型、Paper 與多目標之整體模擬學習成效分析

實驗 2-1 首先比較基線模型的模擬學習成效差異，結果顯示，ZPD 理論在 APR、達標率以及答對率皆優於 Random，而此結果可說明考慮學生的個人狀況與題目難度等資訊進行題目推薦本身即具一定意義，能在模擬環境中提供較大的學習增益。此外，Paper 與多目標組的整體模擬學習成效顯示，多目標並未因加入路徑合理性及無聊懲罰等獎勵而造成模擬學習成效明顯下降，在答對率、達標率等表現和 Paper 組極為相近，兩組差距與種子波動相近。

(二) 學習路徑連貫性及合理性

實驗 2-1 比較兩種獎勵設計所產生的學習路徑後發現，多目標模型較常將推薦內容安排

在學生薄弱的技能、近期答錯的內容等。顯示當獎勵函數納入教學層面的考量後，PPO 的推薦依據不再僅著重於提升 APR，而開始同時考慮學生目前的知識缺口與技能之間的關聯性。

然而，從完整路徑來看，推薦路徑仍會在關聯較弱的技能之間切換，顯示目前的教學邏輯雖然能改變模型的偏好，卻不足以限制模型只能沿著合理的先備關係或相近概念前進。換言之，現有獎勵較像是在眾多可能的推薦中，提高合理路徑被選中的機率，而不是直接規定模型必須依循特定的教學順序。因此，只要某個跨單元題目能帶來較高的預期學習增益，PPO 仍可能選擇該題，造成路徑在教學觀點上出現跳躍，進而出現較多不符合教學邏輯之路徑。

近期錯題補強的改善尤其有限，也反映出目前獎勵設計仍以「間接引導」為主。現有模型會根據學生的弱項、技能關係等調整推薦方向，但「最近答錯的技能」並未被設定為一個獨立的最佳化目標。此設計能提供較大的推薦彈性，但也使模型較難形成明確錯題補強機制。

綜合而言，本研究的多目標獎勵已能使 PPO 的推薦方向由單純追求整體表現提升，逐漸轉向兼顧學生弱項、近期學習情形與知識關係，說明教學邏輯能夠影響推薦策略與偏好。

(三) 不同獎勵函數權重對於推薦結果的影響

實驗 2-2 進一步提高教學邏輯在獎勵函數中的相對比重。結果顯示，提高教學邏輯權重後，多目標模型仍能維持穩定的模擬學習成效，調整學習表現與教學邏輯的相對權重後，各組呈現不同的推薦偏好，部分較高權重設定在弱項、近期錯題或知識關係指標上有所改善。相較於主要追求 APR 提升的 Paper 獎勵，多目標模型的優勢不在於單純取得更高的 APR，而是在維持相近學習表現的同時，將學生需求與教學原則納入推薦決策。

不同權重組各有優勢。W50 的弱項相關推薦率最高，此權重設定可能使模型更加重視知識缺口；W45 則具有最高的近期錯題相關推薦率及相關單元轉移率。與 Paper 組原有結果相比，各較高權重組分別在部分路徑指標上呈現改善，暫無單一設定在所有指標上皆最佳。

然而，各項合理性指標並未隨教學邏輯權重增加而持續上升。可能原因是教學邏輯同時包含弱項補強、技能關係、間隔複習、多樣性及先備知識等目標，這些目標在特定情況下可能互相競爭。例如，推薦另一單元的弱項技能可以提高弱項相關率，卻可能降低相鄰推薦的連貫性。因此，W50 雖然最重視弱項，仍未在所有路徑指標上優於 W45。

綜合而言，權重敏感度實驗顯示，多目標獎勵達標步數可能因教學權重上升而增加。推薦傾向方面，能使推薦策略更重視學生需求與知識關係，這是相較 Paper 獎勵的優勢。但多目

標獎勵的作用主要是調整推薦偏好，尚不足以保證所有推薦皆符合知識圖譜。若重視弱項補強，W50 表現較佳；若考慮兼顧錯題補強與知識銜接方面，則 W45 呈現較均衡的結果。

(四) 教師盲測之結果

兩位教師對相同 14 組推薦路徑的判斷差異明顯，僅兩組結果相同。造成差異的原因可能是，教學合理性同時包含弱項補強、近期錯題、先備順序與路徑連貫性等面向，不同教師重視的標準可能不同。

整體而言，多目標在兩位教師的評估中皆有獲選，顯示部分路徑可能較能回應學生弱項；但由於評估一致性有限，尚不足以證明多目標的教學合理性絕對優於 Paper，而目前研究的主要限制如下：

1. 模擬環境的限制

現有的模擬環境雖然是使用公開資料集進行訓練，且 AKT 模型具有一定的預測能力，但 AKT 之預測結果仍不能完全等同於真實學生的知識變化，RL 仍是在沙盒環境中進行實驗和學習推薦策略，而模擬環境可能相較現實中有偏誤，無法完全模仿並取代真實學生的行為、知識變化、情緒體驗與學習過程，進而導致 RL 在學習過程中受到環境偏差所影響。

2. 教學合理性於 RL 環境的衝突

現實中的合理教學不僅需要考慮學生的學習成效，還須同時兼顧題目難度、先備知識、學習順序、單元關聯、弱項補強等。然而，這些教學原則並非在所有情境下都具有固定的重要性，而是會隨學生當下的知識狀態與學習需求而改變，且不同目標之間可能存在衝突或互相抵銷，導致難以透過獎勵函數形塑合理的推薦行為。

目前結果反映的是僅依靠獎勵權重調整，難以同時處理真實教學中的多重限制。後續研究可在多目標獎勵外，追加先備知識門檻、限定推薦題目範圍或跨單元轉移限制，使教學原則不僅影響模型的推薦偏好，也能直接約束推薦路徑的形成。

三、基於混合 RAG 提升 LLM 問答品質

(一) 動態分流以少數提問的延遲換取整體檢索品質

Hybrid RAG 使 94.0% 的提問於 0.1 秒內完成，其餘 6.0% 進入耗時較長的救援通道，整體檢索命中率達 86.71%。兩條通道的延遲屬性不同，不宜以單一平均值概括。須釐清此處測得者為檢索階段延遲，不含 LLM 生成回覆時間；因此本設計的定位為「使檢索不成為額

外的感知延遲來源」——94.0% 的提問其檢索時間遠低於生成時間，僅 6.0% 的救援通道（單題 14.7 秒）會成為主要延遲。實際注入模型的深度為 Top-5，其命中率為 54.15%，需與檢索結果分開討論。

(二) RAG 的品質優勢跨模型成立

自雲端大模型至可離線部署的 4B 邊緣模型，RAG 組在兩位裁判下均穩定勝出，惟優勢部分來自回覆長度，且隨模型規模縮減而下降。顯示模型本身仍須具備重組教材的能力。控制回覆長度與引用線索後優勢依然存在，故非單純的 LLM 偏見所致，詳見附錄一（四）、（五）。

四、本研究透過 3 項實驗探究，將研究所得結論實作整合為如圖 6-1 所示的完整架構。整合後的操作畫面詳見附錄三。




圖 6-1：本研究架構整合之流程圖（圖片來源：作者自製）

柒、結論與未來方向

一、研究結論

- (一) 實驗一核心研究與延伸驗證顯示，中小型模型的數學程式生成表現同時受到工具覆蓋與流程規劃負擔影響，僅提供 API 不一定能提升功能正確性。
- (二) 實驗一核心研究中，Healer 於 342 格原始 FAIL 中救回 9 格（2.63%），僅修復程式結構、介面、資料流及輸出格式，不修改數學答案或主要演算法。
- (三) 實驗二的多目標獎勵能在維持模擬環境學習成效的同時，使推薦方向更重視學生弱項與知識關係，使推薦合理性獲得初步改善，但教師評估一致性較低，仍需後續驗證。

(四) 實驗三在 LLM 合成資料條件下，混合檢索以動態分流使絕大多數提問於 1 秒內完成，候選池深度 $K=41$ 之命中率為 86.71%，實際注入模型之 Top-5 命中率為 54.15%。因提問與教材皆為合成，上述數值應視為效能上限，真實學生提問下之表現尚待驗證。

(五) 實驗三 RAG 輔助的教學品質優勢自雲端大模型延伸至可離線部署的邊緣端小模型。

二、未來方向與展望

(一) 擴大題目、模型與學科範圍，驗證方法的泛化能力。

(二) 擴充可安全判定的 Healer 規則，並進行本地端部署與實際效能評估。

(三) 進一步導入真實學生資料與教師評估，提升系統之外部效度。

(四) 推薦模型可加入先備知識限制與更完整的學生情感訊號等，以改善學習路徑連貫性。

(五) 建立繁體中文數學檢索評估資料集，以真實資料重現實驗。

捌、參考資料

- [1] S. Frieder et al., “Mathematical capabilities of ChatGPT,” Adv. Neural Inf. Process. Syst., vol. 36, 2023.
- [2] L. Gao et al., “PAL: Program-aided language models,” in Proc. 40th Int. Conf. Mach. Learn. (ICML), vol. 202, 2023, pp. 10764–10799.
- [3] S. Bagheri Nezhad, Y. Li, and A. Agrawal, “SymCode: A neurosymbolic approach to mathematical reasoning via verifiable code generation,” in Findings Assoc. Comput. Linguistics: EACL, 2026, pp. 1489–1503.
- [4] J. Liu, C. S. Xia, Y. Wang, and L. Zhang, “Is your code generated by ChatGPT really correct? Rigorous evaluation of large language models for code generation,” Adv. Neural Inf. Process. Syst., vol. 36, pp. 21558–21572, 2023.
- [5] J. Li, G. Li, Y. Li, and Z. Jin, “Structured chain-of-thought prompting for code generation,” ACM Trans. Softw. Eng. Methodol., vol. 34, no. 2, Art. no. 37, pp. 1–23, 2025.
- [6] S. Zhou et al., “DocPrompting: Generating code by retrieving the docs,” in Proc. 11th Int. Conf. Learn. Represent. (ICLR), 2023.
- [7] Z. Fan, X. Gao, M. Mirchev, A. Roychoudhury, and S. H. Tan, “Automated repair of programs from large language models,” in Proc. 45th IEEE/ACM Int. Conf. Softw. Eng. (ICSE), 2023, pp. 1469–1481.
- [8] D. Khati, D. Rodriguez-Cardenas, P. Pantzer, and D. Poshyvanyk, “Detecting and correcting hallucinations in LLM-generated code via deterministic AST analysis,” in Proc. 3rd IEEE/ACM Int.

Conf. AI Found. Models Softw. Eng. (FORGE), 2026.

[9] H. Li et al., “Bringing generative AI to adaptive learning in education,” arXiv preprint arXiv:2402.14601v3, 2024.

[10] A. Ghosh, N. Heffernan, and A. S. Lan, “Context-aware attentive knowledge tracing,” in Proc. 26th ACM SIGKDD Int. Conf. Knowl. Discovery Data Mining (KDD), 2020, pp. 2330–2339.

[11] J. Schulman, F. Wolski, P. Dhariwal, A. Radford, and O. Klimov, “Proximal policy optimization algorithms,” arXiv preprint arXiv:1707.06347, 2017.

[12] A. Raffin et al., “Stable-Baselines3: Reliable reinforcement learning implementations,” J. Mach. Learn. Res., vol. 22, no. 268, pp. 1–8, 2021.

[13] J.-Y. Chen, S. Saeedvand, and I.-W. Lai, “Adaptive learning path navigation based on knowledge tracing and reinforcement learning,” arXiv preprint arXiv:2305.04475, 2023.

[14] L. S. Vygotsky, *Mind in Society: The Development of Higher Psychological Processes*. Cambridge, MA, USA: Harvard Univ. Press, 1978.

[15] F. M. Lord, *Applications of Item Response Theory to Practical Testing Problems*. Hillsdale, NJ, USA: Lawrence Erlbaum Associates, 1980.

[16] Y. Gao et al., “Retrieval-augmented generation for large language models: A survey,” arXiv preprint arXiv:2312.10997, 2023.

[17] L. Zheng et al., “Judging LLM-as-a-judge with MT-Bench and Chatbot Arena,” Adv. Neural Inf. Process. Syst., vol. 36, pp. 46595–46623, 2023.

[18] M. O. Z. San Pedro, J. Ocumpaugh, R. S. Baker, and N. T. Heffernan, “ASSISTments longitudinal data mining competition special issue: A preface,” J. Educ. Data Mining, vol. 12, no. 2, pp. i–x, 2020.

[19] H. van Hasselt, A. Guez, M. Hessel, V. Mnih, and D. Silver, “Learning values across many orders of magnitude,” Adv. Neural Inf. Process. Syst., vol. 29, 2016.

[20] Junyi Academy, “Junyi Academy Dataset,” 2023. [Online]. Available: <https://www.junyiacademy.org/>


[21] M. D. Gall, “The use of questions in teaching,” Rev. Educ. Res., vol. 40, no. 5, pp. 707–721, 1970.

[22] J. Nielsen, *Usability Engineering*. San Francisco, CA, USA: Morgan Kaufmann, 1993, pp. 134–135.

玖、附錄

附錄一、基於 RAG 改善學生提問回覆研究（實驗三）


（一）實驗 3-2 Hybrid RAG 分流



附圖 1：Hybrid RAG 命中率分布（圖片來源：作者自製）


附圖 1 顯示，6.0% 的困難迷思提問觸發救援通道 (Advanced RAG)，其中 5.3% 命中。而快速通道的 12.6% 誤判集中於教材文本高度相似的單元，屬於本檢索設定下的已知限制。

（二）人類教師與 Claude 裁判之判決占比




附圖 2：人類教師與 Claude 裁判之判決占比（圖片來源：作者自製）

(三) 邊緣端模型與雲端模型之勝率



附圖 3：邊緣端模型與雲端模型之 RAG 勝率對比（圖片來源：作者自製）


(四) 教材引用揭露檢驗



附圖 4：教材引用揭露檢驗（圖片來源：作者自製）

由於邊緣端模型的 RAG 回覆有半數會主動引述教材，可能使裁判辨識出組別。故將 301 題依此切分為互斥的兩個子集（有引述 157 題、未引述 144 題），各自計算判決分布。兩子集的 RAG 獲勝率差異在三個百分點以內，且在未引述教材的子集中 RAG 仍明顯優於純 LLM，顯示判決結果並非由引用線索導致。

(五) 回覆長度與判決結果之關係



附圖 5：長度偏見檢驗——控制回覆長度後之判決分布（圖片來源：作者自製）

為排除裁判偏好較長回覆的可能，本研究依「哪一組回覆較長」將 301 題分層檢驗。在 RAG 回覆較長的 232 題中，RAG 獲勝率為 69.8%（Claude 裁判）與 78.4%（Gemini 裁判）；在純 LLM 回覆較長的 69 題中，RAG 獲勝率降至 58.0% 與 50.7%，但仍不低於純 LLM 的 31.9% 與 43.5%。控制長度後，RAG 的優勢明顯縮小，惟未逆轉為劣勢。故 RAG 的品質優勢有一部分來自回覆長度，其獨立於長度的效果小於主結果所呈現的幅度。

(六) 實驗 3-3 LLM-as-a-Judge 提示詞

你是一位嚴格且專業的「數學教學評審」。我將會給你一個包含多筆資料的列表，每筆資料包含一個數學主題 (topic)、學生的提問 (test_query)，以及兩個不同的教學回覆 (Answer_A 與 Answer_B，順序已打亂)。

【評分標準 (Guidelines)】

請比較 A 與 B 哪個是更好的教學回覆。一個好的數學教學回覆必須具備：

正確與精準：數學概念正確，且緊扣單元主題。

避免長度偏見 (Verbosity Bias)。

教學結構：使用條列式。

邏輯與符號：清楚定義代數符號或幾何點位，Latex 語法錯誤與出現的[Image...] 標示都不列入評分標準。

人設穩定：語氣應為引導學生的老師，若出現幻覺則為嚴重缺失。

【系統標記說明 (務必遵守)】

回覆中若出現「【參考單元 N】」、「【單元 N】」、「參考教材」、「根據教材」、「教材內容」等字樣，那是本實驗系統在生成時提供給模型的課綱教材引用標記，這些教材真實存在，只是未一併呈現給你。因此：(1) 不得將這類引用判定為幻覺、捏造、虛構來源或不存在的內容；(2) 同時也不得因為出現引用標記而給予任何加分。請完全忽略引用標記本身的有無，只依據數學內容的正確性、教學結構、符號定義與人設穩定度來比較兩份回覆。唯有當回覆的數學內容本身錯誤時，才計為幻覺或嚴重缺失。

【參考範例 (Few-Shot Example)】

假設學生的提問是關於「圓外一點到圓的兩切線段等長」，以下是評估基準：

<bad_example>「是的，老師，您的理解是正確的！... (缺乏符號定義，且稱呼學生為老師，缺乏視覺層次)」-> 判定為劣勢。</bad_example>

<good_example>「其實不會不一樣長，而是兩條切線段一定一樣長。假設圓心是 O ，圓外的點是 P ，兩個切點是 A 和 B 。根據垂直性質 $OA \perp PA$ ，所以 $\triangle OAP$ 和 $\triangle OBP$ 都是直角三角形... (結構清晰，有代數符號，且同理學生的直覺盲點)」-> 判定為優勢。</good_example>

【任務指令】

請一次性評估下方提供的所有資料，並嚴格輸出以下 JSON 陣列格式，不需輸出任何其他文字：

JSON[

{

"node_id": "(對應題目的 ID)",

"critique": "(簡短評論：根據評分標準，為什麼選這個？另一個哪裡犯了錯或表現較差？)",

"winner": "Answer_A 或 Answer_B 或 Tie"

}

]

以下是待評估的資料：

附錄二、現有平台缺陷與自適應輔助學習系統之比較

因材網是由台灣教育部推出的數位學習平台，雖具備適性學習與生成式 AI 輔助，但仍有許多限制。其缺點如附表 1 所示。本研究針對以上缺點探討可能的解法，並如附表 2 所示以人工智慧相關技術克服這些瓶頸。


附表 1：因材網缺點（表格來源：作者自製）

缺點	對學生造成問題
出題機制	固定題庫，學生容易背答案
教材來源	官方固定，較難根據學生客製化調整
推薦題目機制	教師指派，較難根據學生狀況調整
診斷答錯原因	呼叫 AI 回覆，回答可能與課綱不一致

附表 2：自適應輔助學習系統與現有平台比較（表格來源：作者自製）

比較項目	因材網	自適應輔助學習平台（本作品）
出題機制	固定	本地模型生成無限題庫
教材來源	官方固定	學生上傳題目或老師上傳教材自動生成無限題庫
主動推薦題目	老師指派	RL 自適應推薦題目
診斷答錯原因	純呼叫 LLM	RAG 根據教材回答與推薦迷思觀念題目練習

附錄三、自適應輔助學習架構操作畫面展示



附圖 6：自適應輔助學習架構操作畫面（圖片來源：作者自製）

附錄四、強化學習實驗各項參數

附表 3：實驗 2 實驗設定及各項參數（表格來源：作者自製）

參數	設定
Policy	MlpPolicy
Hidden layers	256、256
Activation	ReLU
Learning rate	0.0003
n_steps	2,048
Batch size	64
n_epochs	10
Gamma	0.99
GAE lambda	0.95
Clip range	0.2
Entropy coefficient	0.01
Max gradient norm	0.5
Timesteps	每 seed 1,000,000
Seeds	0、1、2
觀察空間	673 題預測答對機率 + 目前 APR + 剩餘步數比例 + 連續失敗次數 + 連續同技能次數，共 677 維
動作空間	673 道題目中選擇下一題
模擬作答方式	依 AKT 預測答對機率進行 Bernoulli 隨機抽樣
狀態更新	將推薦題目、技能與模擬作答結果加入歷史，再由 AKT 重新預測
達標條件	skill-balanced APR ≥ 0.65
最長路徑	60 步
終止方式	APR 達標時終止；達 60 步時截斷
PPO 執行環境	單一 DummyVecEnv
評估規模	每組 3 個種子 $\times$ 100 位固定測試學生 = 300 條路徑

正式 PPO 訓練學生	400 位
固定測試學生	100 位
初始歷史	最早 5 筆有效作答
最低紀錄要求	至少 7 筆
初始條件	初始 skill-balanced APR < 0.65
測試學生是否參與校準 ／選權重	否

附表 4：教學邏輯獎勵項目（表格來源：作者自製）

項目	權重	目標
技能關係	0.35	鼓勵先備、補救、明確相關或同群組技能間的轉移
學習弱項	0.30	優先推薦學生目前較薄弱且適合補強的技能
難度鷹架	0.20	鼓勵題目難度符合學生當下的預測狀態
多樣性	0.15	避免長時間停留於單一技能，同時保留教學關聯
先備不足懲罰	0.25	降低學生尚未具備先備狀態時直接進入後續技能
過度重複懲罰	0.10	降低長時間推薦重複題目

附表 5：教學邏輯判定規則（表格來源：作者自製）

教學考量	判定設定	說明
先備知識 是否足夠	0.60	若 AKT 預測學生對先備技能的平均答對機率低於 60%，表示先備知識可能尚未穩定；此時若直接推薦後續技能，將降低該推薦的教學邏輯分數。
題目難度 是否適合	目標答對機率 0.60	系統較偏好 AKT 預測學生約有 60% 機率能答對的題目，使題目具有一定挑戰性，但不至於過難。
難度可接受 範圍	± 0.30	以 60% 為中心，預測答對機率約 30% 至 90% 的題目皆可能取得難度適配分數；越接近 60%，難度適配分數越高。
題目是否 過於簡單	0.85	若學生答對該題，且作答前的預測答對機率高於 85%，表示題目可能過於簡單，系統會加入少量扣分；若屬間隔複習或失敗後補強，則不一定視為過度簡單。
是否形成 間隔複習	相隔 5 步	同一技能經過至少 5 個推薦步驟後再次出現，視為間隔複習，而非單純重複推薦。
是否過度 集中於同 一技能	前 3 次不扣分	系統允許同一技能在短期內連續練習最多 3 次，以完成概念鞏固；超過後才逐步加入重複推薦扣分。
是否持續 遭遇失敗	最多計算 5 次 連錯	學生連續答錯越多，失敗風險扣分越高；計算至連續 5 次為止，避免懲罰數值無限制增加。

附表 6：31 個技能之群組分類（表格來源：作者自製）

技能 群組	技能
數與 運算	加法（addition）、除法（division）、數字排序（ordering-numbers）、數線（number-line）、運算順序（order-of-operations）、指數（exponents）
分數 與百 分比	分數（fractions）、最小公倍數（least-common-multiple）、分數乘法（fraction-multiplication）、分數除法（fraction-division）、百分比（percents）

代數	代數樣式與關係 (p-patterns-relations-algebra)、理解算式與方程式 (making-sense-of-expressions-and-equations)、方程式概念 (equation-concept)、不等式求解 (inequality-solving)
速率與測量	單位換算 (unit-conversion)、長度面積體積換算 (linear-area-volume-conversion)、速率 (rate)、距離—速率—時間 (rate-with-distance-and-time)
幾何	幾何圖形性質 (properties-of-geometric-figures)、周長 (perimeter)、補角 (supplementary-angles)、三角形內角和 (sum-of-interior-angles-triangle)、等腰三角形 (isosceles-triangle)、多邊形內角和 (sum-of-interior-angles-more-than-3-sides)、截線與平行線 (transversals)、旋轉變換 (transformations-rotations)、畢氏定理 (pythagorean-theorem)
資料與計數	文氏圖 (venn-diagram)、圓形圖 (circle-graph)、組合計數 (combinatorics)

附表 7：知識圖譜之先備關係（表格來源：作者自製）

先備技能	後續技能	說明
數字排序	數線	先理解數值大小與排序，再將數字放置於數線上。
加法	運算順序	理解基本加法後，再學習包含多種運算的計算順序。
除法	運算順序	理解除法後，再處理包含除法的混合運算。
分數	分數乘法	先理解分數概念，再學習分數乘法。
分數	分數除法	先理解分數概念，再學習分數除法。
除法	分數除法	先理解除法意義，再理解分數除法。
分數	百分比	先理解部分與整體的分數表示，再學習百分比。
百分比	圓形圖	先理解百分比，再解讀圓形圖中各部分所占比例。
理解算式與方程式	方程式概念	先理解代數式與等式的意義，再建立方程式概念。
方程式概念	不等式求解	先具備方程式的移項與求解概念，再學習不等式。
除法	速率	速率通常以兩個數量相除表示，因此需先理解除法。
速率	距離、速率、時間	先理解速率，再處理距離、速率與時間之間的關係。
單位換算	長度面積體積換算	先理解一般單位換算，再處理長度、面積與體積的不同次方換算。
幾何圖形性質	周長	先理解圖形的邊與基本性質，再計算圖形周長。
幾何圖形性質	補角	先理解基本幾何圖形與角，再學習補角關係。
幾何圖形性質	三角形內角和	先理解三角形及角的基本性質，再學習三角形內角和。
三角形內角和	等腰三角形	先理解三角形內角關係，再分析等腰三角形的角度性質。

三角形內角和	多邊形內角和	可利用三角形分割推導多邊形內角和。
補角	截線與平行線	先理解角與補角關係，再判斷截線形成的各種角。
幾何圖形性質	旋轉變換	先理解圖形基本性質，再學習圖形旋轉後的對應關係。
幾何圖形性質	畢氏定理	先理解三角形與直角三角形等基本幾何性質。
指數	畢氏定理	先理解平方運算，再使用畢氏定理中的平方關係。

附表 8：知識圖譜之明確相關技能(表格來源：作者自製)

技能一	技能二	關係說明
數字排序	數線	兩者皆涉及數值大小與位置。
分數	數線	分數可表示為數線上的位置。
分數	最小公倍數	分數通分通常需要使用最小公倍數。
百分比	速率	兩者皆涉及兩個數量之間的比值關係。
百分比	圓形圖	圓形圖常使用百分比呈現資料比例。
指數	運算順序	指數是混合運算順序中的一部分。
代數樣式與關係	理解算式與方程式	兩者皆涉及代數表示與數量關係。
單位換算	速率	速率計算常需要統一距離與時間單位。
單位換算	周長	周長計算可能涉及長度單位換算。
長度面積體積換算	周長	兩者皆涉及幾何測量及單位處理。
補角	截線與平行線	平行線與截線問題常使用補角關係。
三角形內角和	等腰三角形	等腰三角形的角度推理會使用三角形內角和。
三角形內角和	多邊形內角和	多邊形內角和可透過三角形分割推導。
畢氏定理	等腰三角形	部分等腰三角形問題可利用畢氏定理求邊長或高。
文氏圖	組合計數	文氏圖可用於分析集合交集與計數。
文氏圖	圓形圖	兩者皆可用於整理及呈現資料分類。

附表 9：知識圖譜之關係分數表(表格來源：作者自製)

前後技能關係	比重	說明
依先備順序前進	1.00	學生先練習基礎技能，再進入需要運用該基礎的進階技能，最符合循序漸進的教學方式。例如先學「分數」，再學「分數乘法」。
回到先備技能補救	0.75	學生在進階技能上遇到困難時，系統回頭推薦相關的基礎技能，協助學生補足可能缺少的先備知識。例如學生在「分數除法」表現不佳，系統改推薦「分數」或「除法」。

明確相關技能	0.75	前後兩項技能未必有固定的先後順序，但兩者在概念或解題方法上有直接關聯，因此安排在一起仍具有教學意義。例如「百分比」與「圓形圖」都涉及比例概念。
同技能群組	0.50	前後技能屬於相同數學領域，但知識圖譜沒有設定直接的先備或相關關係。例如「周長」與「旋轉變換」都屬於幾何，但概念關係較不直接。
同技能連續三題以內	0.25	系統短時間內繼續推薦相同技能，讓學生進行集中練習。前三題仍視為合理的鞏固練習，但因為沒有產生新的技能銜接，所以分數較低。超過三題後，還可能受到重複推薦懲罰。
未定義或跨單元	0.00	前後技能在目前的知識圖譜中沒有已知關係，或突然切換到其他數學單元。例如上一題是「分數乘法」，下一題直接變成「旋轉變換」。這種轉換不會得到技能關係獎勵，但不代表它一定錯誤。